

**UNIVERSIDADE FEDERAL DE SANTA CATARINA
DEPARTAMENTO DE COMPUTAÇÃO**

Thiago Raulino Dal Pont

**UM MODELO DE GELADEIRA INTELIGENTE QUE
LEVA EM CONTA AS PREFERÊNCIAS E HÁBITOS DE
SEUS USUÁRIOS**

Araranguá

2017

Thiago Raulino Dal Pont

**UM MODELO DE GELADEIRA INTELIGENTE QUE
LEVA EM CONTA AS PREFERÊNCIAS E HÁBITOS DE
SEUS USUÁRIOS**

Trabalho de Conclusão de Curso
submetido à Universidade Federal
de Santa Catarina, como parte dos
requisitos necessários para a obten-
ção do Grau de Bacharel em Enge-
nharia de Computação.

Orientador: Prof. Alexandre Leo-
poldo Gonçalves, Dr.

Araranguá
2017

RESUMO

Nas últimas duas décadas conceito da Internet das Coisas vem se popularizando, propondo a introdução da tecnologia e da interconexão de objetos distintos, como lâmpadas, geladeiras, carros, etc., através de uma rede, frequentemente, a Internet. Assim, o número de aparelhos interligados tende a crescer e altas quantidades de dados serão produzidas. É, então, necessário o uso de ferramentas capazes de processar e extrair informações relevantes desses dados. Entre os métodos existentes estão os sistemas de recomendação, aos quais, a partir de análises dos registros, são capazes de traçar o perfil de usuários e fornecer sugestões. Nos últimos anos, esses sistemas vêm sendo incorporados em diversos contextos como plataformas de streaming e, gradativamente, aplicações introduzirão essas ideias no âmbito da Internet das Coisas. Entre os ambientes, nos quais é possível integrar ambos os conceitos, estão as casas inteligentes ou smart homes, onde o uso da tecnologia abre caminho para novas formas de interação com o lar. Dispositivos comuns como geladeiras agregam tecnologias e novas funcionalidades, no entanto, os modelos existentes apenas proporcionam interações digitais, contudo não atentam aos gostos e hábitos dos usuários. Levando isso em conta, o presente trabalho propõe um novo modelo de geladeira capaz de monitorar as interações e traçar perfil de preferências em produtos. Isso é possível graças ao uso de etiquetas RFID, que terão o papel de identificar os diversos produtos contidos na geladeira e da aplicação de algoritmos de recomendação. Ao final, o equipamento será capaz de oferecer novos produtos ao usuário de acordo com o seu perfil, além de promoções de itens relacionados e sugestões de receitas que englobem produtos contidos na geladeira.

Palavras-chave: Internet das Coisas. Sistemas de Recomendação. Geladeira Inteligente. Preferências do usuário.

ABSTRACT

In the last two decades the concept of the Internet of Things has become popular, proposing the introduction of technology and the interconnection of different objects such as lamps, refrigerators, cars, etc. through a network, often the Internet. Thus, the number of interconnected devices tends to grow and high amounts of data will be produced. It is then necessary to use tools capable of processing and extracting relevant information from this data. Among the existing methods are the recommendation systems, which, from the analysis of the records, are able to trace the users profile and provide suggestions. In recent years, these systems have been incorporated in a variety of contexts as streaming platforms and, gradually, applications will introduce these ideas into the Internet of Things. Among the environments in which both concepts can be integrated are smart houses, where the use of technology opens the way to new forms of interaction with the home. Common devices such as refrigerators add technologies and new features, however, the existing models only provide digital interactions, however do not pay attention to the tastes and habits of users. Taking this into account, the present work proposes a new refrigerator model capable of monitoring interactions and tracing preferences profile in products. This is possible thanks to the use of RFID tags, which will have the role of identifying the various products contained in the refrigerator and the application of recommendation algorithms. In the end, the equipment will be able to offer new products to the user according to their profile, as well as promotions of related items and suggestions of recipes that include products contained in the refrigerator

Keywords: Internet of Things. Recommender systems. Smart fridge. User preferences

LISTA DE FIGURAS

Figura 1.1	Fluxo das Etapas do Trabalho.....	23
Figura 2.1	Arquiteturas para IoT.....	26
Figura 2.2	Arquitetura básica para o IEEE802.11.....	35
Figura 2.3	Modelo para casas inteligentes.....	39
Figura 3.1	Exemplo de grupos para classificação com o kNN....	50
Figura 3.2	Exemplo de classificação com o kNN	51
Figura 3.3	Rede Percéptron de Múltiplas Camadas	54
Figura 4.1	Modelo lógico	66

LISTA DE TABELAS

Tabela 2.1	Resumo dos protocolos 802.11.....	35
Tabela 3.1	Matriz de avaliações de itens por usuários.....	46

LISTA DE ABREVIATURAS E SIGLAS

WPAN	<i>Wireless Personal Area Network</i>
IEEE	<i>Institute of Electrical and Electronics Engineers</i>
ISM	<i>Industrial Scientific and Medical</i>
TDM	<i>Time-Division Multiplexing</i>
BR/EDR	<i>Basic Rate/Enhanced Data Rate</i>
BLE	<i>Bluetooth Low Energy</i>
RFID	<i>Radio-Frequency IDentification</i>
NFC	<i>Near Field Communication</i>
NDEF	<i>NFC Data Exchange Format</i>
PDF	<i>Portable Document Format</i>
URL	<i>Uniform Resource Locator</i>
WLAN	<i>Wireless Local Area Network</i>
OSI	<i>Open System Interconnection</i>
BSS	<i>Basic Service Set</i>
AES	Advanced Encryption Standard

LISTA DE SÍMBOLOS

\int	Integral
Ω	Ômega
ω	Ômega

SUMÁRIO

1	INTRODUÇÃO	17
1.1	PROBLEMÁTICA	20
1.2	OBJETIVOS	21
1.2.1	Geral	21
1.2.2	Específicos	21
1.3	JUSTIFICATIVA E MOTIVAÇÃO	21
1.4	PROCEDIMENTOS METODOLÓGICOS	23
1.5	ORGANIZAÇÃO DO TRABALHO	24
2	INTERNET DAS COISAS	25
2.1	ARQUITETURA	26
2.2	TECNOLOGIAS	27
2.2.1	Bluetooth	27
2.2.1.1	Categorias	28
2.2.1.2	Bluetooth 5.0	29
2.2.2	RFID	30
2.2.3	NFC	31
2.2.4	Zigbee	32
2.2.5	Wi-Fi	34
2.2.6	Outros	36
2.3	AMBIENTES INTELIGENTES	37
2.3.1	Smart grid	37
2.3.2	Smart home	37
2.3.3	Outros	40
2.4	DESAFIOS	41
3	SISTEMAS DE RECOMENDAÇÃO	43
3.1	HISTÓRICO	43
3.2	FILTRAGEM COLABORATIVA (FC)	45
3.2.1	Baseado em memória	46
3.2.1.1	Medidas de Similaridade	46
3.2.1.2	k Vizinhos Mais Próximos (kNN)	49
3.2.2	Baseado em modelo	51
3.2.2.1	Fatoração de matriz	51
3.2.2.2	Métodos Probabilísticos	52
3.2.2.3	Redes Neurais	53
3.2.2.4	Baseado em regras de associação	54
3.3	BASEADA EM CONTEÚDO	55
3.3.1	Descrição do item	55

3.3.2	Perfil de usuário	57
3.3.3	Recomendação	57
3.4	BASEADA EM CONHECIMENTO	57
3.4.1	Baseado em restrições	58
3.4.2	Baseado em caso	59
3.5	ABORDAGEM HÍBRIDA	59
3.6	OUTRAS ABORDAGENS	60
3.6.1	Baseada em Contexto	61
3.6.2	Baseada em Utilidade	61
3.6.3	SRs Sociais	62
3.6.4	SRs Demográficos	62
3.7	DESAFIOS	62
3.8	APLICAÇÕES	63
4	SISTEMA PROPOSTO	65
4.1	INTRODUÇÃO	65
4.2	ARQUITETURA	65
4.2.1	Modelo lógico	65
4.2.1.1	Camada de Aplicação	65
4.2.1.2	Camada de Serviços	66
4.2.1.3	Camada de Repositórios	68
4.2.1.4	Camada de Processamento	68
4.2.2	Modelo físico	69
4.2.3	Exemplo de fluxo de execução	69
5	AVALIAÇÃO DO SISTEMA PROPOSTO	71
6	CONSIDERAÇÕES FINAIS	73
6.1	CONCLUSÕES	73
6.2	TRABALHOS FUTUROS	73
	REFERÊNCIAS	75

1 INTRODUÇÃO

Nas últimas décadas, presencia-se os acelerados avanços na ciência e tecnologia impulsionados por empresas dos mais diversos ramos e pelas constantes pesquisas nas universidades.

Um dos avanços tecnológicos mais significativos é a Internet, com efeito significativo no desenvolvimento da economia global e na sociedade atual. Em duas décadas tem decorrido um grande crescimento na disponibilidade do acesso à rede. Em setembro de 2016, o número de usuários da rede mundial de computadores era de aproximadamente 3,75 bilhões, quase metade da população mundial e cerca de 92 vezes maior em relação ao ano 2000 (MINIWATTS MARKETING GROUP, 2016). Outro grande avanço tem ocorrido nos celulares, aos quais evoluíram tanto nos últimos anos que passaram de simples e grandes telefones sem fio à dispositivos menores, no entanto, com acesso à Internet, recursos avançados de áudio e vídeo e poder de processamento equiparável à computadores de mesa (*desktops*) e/ou notebooks (MEYERS, 2011; WOYKE, 2014).

Em meio ao contexto da Internet, um novo paradigma surgiu no meio acadêmico e aos poucos ganha terreno nas grandes empresas. A sua proposta é levar a tecnologia a objetos do dia a dia, como condicionadores de ar, lâmpadas, fogões etc., e, assim, criar novas formas de interação além de funcionalidades inéditas, seguindo o exemplo dos *smartphones*.

Mencionada pela primeira vez, por Kevin Ashton, em 1999 (FINEP, 2015), a Internet das Coisas ou IoT (em inglês, *Internet of Things*) vem se consolidando cada vez mais. Abrigará um variado ecossistema de dispositivos com capacidade de processamento, sensoriamento, conexão com demais dispositivos, em muito casos, com a Internet, entre outros avanços. Estima-se que, em 2020, cerca de 24 bilhões de dispositivos IoT estejam conectados, implicando em torno de quatro dispositivos por pessoa (MEOLA, 2016). Contudo, com o crescimento do número de itens computacionais, a quantidade de dados gerada por eles também cresce de maneira acelerada (CHIANG; ZHANG, 2016). A partir disso, o fluxo de dados na rede de internet se intensifica a ponto de comprometer o seu desempenho. Isso decorre do modelo de rede utilizado, também chamado *cloud computing*, ao qual mantêm recursos e funcionalidades distantes dos dispositivos que os utilizam, ou seja, em servidores e *data centers*. Assim, para obtenção de tais recursos há a necessidade dos dispositivos em acessar a nuvem através da internet

sempre que necessário, gerando, desse modo, um alto tráfego de dados (VAQUERO; RODERO-MERINO, 2014). Além disso, o acesso a nuvem dificulta aplicações em IoT em tempo real devido ao atraso entre envio e recebimento de dados pela rede de internet (SYED; FERNANDEZ; ILYAS, 2016). Portanto, uma nova arquitetura se faz necessária para incorporar os dispositivos IoT à Internet tradicional. Nesse contexto, a *fog computing* ou computação de neblina, surge como potencial solução, com base na proposta de uma forma de organização de rede que complemente a atual. Isso é possível com base na aproximação de algumas funcionalidades e recursos que atualmente são acessados através da nuvem, ou seja, centralizadas em servidores e data centers, aos dispositivos IoT que as utilizam. (CHIANG; ZHANG, 2016). Para tanto, um dispositivo de rede seria responsável por uma “nuvem local” ou *fog*. Desse modo, os dispositivos IoT se comunicariam com esse equipamento e obteriam funcionalidades necessárias de maneira mais eficiente. Ademais, a nuvem local se comunicaria diretamente com a nuvem convencional, transferindo apenas informações mais relevantes e necessárias (SYED; FERNANDEZ; ILYAS, 2016).

Os dispositivos que compõem a Internet das Coisas podem ser denominados objetos inteligentes, ou *smart objects*, aos quais detêm funcionalidades expandidas como comunicação, sensoriamento, processamento e atuação sobre o ambiente, promovem a interação entre o mundo físico (analógico) e o mundo digital (STOJKOSKA et al., 2017). Isso ocorre graças a sensores capazes de capturar grandezas como temperatura e luminosidade e, a partir disso, possibilita que aplicações tenham conhecimento do contexto do ambiente. Baseando-se nesses conceitos, algumas companhias vêm inserindo no mercado novos produtos com as características citadas. Como exemplo, é citável o Amazon Echo¹, um dispositivo que opera com o serviço de assistente pessoal Alexa, e interage com pessoas em uma casa a partir de comando de voz. Outro produto destacável é a *smart lock* da empresa Nuki², pelo qual é possível abrir e fechar a porta apenas com um toque no aplicativo móvel pelo *smartphone* ou através de um *smart watch*. Outras áreas vem se utilizando desses conceitos, por exemplo, os esportes. O CARV³, um dispositivo vestível ou *wearable*, propõe um calçado para praticantes de ski capaz de analisar em tempo real o modo de esquiar e fornecer informações detalhadas visando melhorar o desempenho dos

¹<https://www.amazon.com/Amazon-Echo-Bluetooth-Speaker-with-WiFi-Alexa/dp/B00X4WHP5E>

²<https://nuki.io/en/shop/nuki-smart-lock/>

³<https://www.kickstarter.com/projects/333155164/carv-the-worlds-first-wearable-that-helps-you-ski>

usuários.

Os *smart objects* poderão, a partir da IoT, operar em conjunto com o objetivo de compor os chamados *smart environments*, ambientes nos quais a integração dos dispositivos agrega novas funcionalidades e formas de interação para determinado ambiente (ASANO; YASHIRO; SAKAMURA, 2016). Entre os ambientes inteligentes emergentes estão as *smart grids*, que propõem a atualização do sistema elétrico atual a partir do uso da tecnologia. Uma das principais mudanças será o direcionamento do fluxo de energia e informações em dois sentidos. Como consequência, será possível consumir e fornecer energia para o sistema elétrico, bem como trocar informações sobre o estado da rede de eletricidade, o consumo, entre outros avanços. Tudo isso será viável em virtude da capacidade de sensoramento, troca de informações, controle e da tecnologia da informação e comunicação (CECILIA; SUDARSANAN, 2016).

Além das *smart grids*, outro ambiente em expansão é a *smart home* ou casa inteligente. Através dela, os moradores de uma casa podem interagir com um recinto capaz de responder ao seus comportamentos e prover diversas funcionalidades (SILVA et al., 2012). Isso se deve à presença de dispositivos dotados com tecnologias de sensoramento, controle e comunicação.

Os ambientes inteligentes podem abrigar outros menores. No caso das *smart homes*, é possível subdividi-las em ambientes como a cozinha inteligente ou *smart kitchen*. Nesse espaço, usuário tem à disposição novas maneiras de interagir com os utensílios e eletrodomésticos. A partir disso, surgem diversas oportunidades em termos de criação de produtos, como geladeiras, fogões, cafeteiras conectadas à Internet. Em relação às geladeiras inteligentes ou *smart fridges*, por exemplo, viu-se um avanço nos últimos anos. Desde os anos 2000 vem-se pensando em como conectar refrigeradores à Internet, sendo a LG⁴ uma das primeiras companhias a implementar o conceito de dispositivos conectados à Internet. Em pesquisas recentes, propõe-se adicionar outros recursos como monitoramento dos produtos no interior e seus respectivos prazos de validade, entre outros (HACHANI et al., 2016).

As interações das pessoas com os ambientes e dispositivos conectados, no contexto da Internet das Coisas, gerará uma grande quantidade de dados (CHIANG; ZHANG, 2016). Um aproveitamento eficiente desses dados pode ampliar as aplicações da IoT. Uma das diversas formas para colocar essa ideia em prática são os sistemas de recomendação. Com base nas preferências indicadas pelo usuário ou no seu comporta-

⁴<http://www.lg.com>

mento, esses sistemas buscam selecionar e fornecer informações relevantes (FILHO; GEUS; ALBUQUERQUE, 2008). Sistemas de recomendação podem ser divididos em três classes principais. A primeira refere-se a filtragem colaborativa, em que recomendações são realizadas com base na similaridade das preferências de determinado usuários em relação a outros usuários no que tange a produtos, serviços etc., que o usuário não conhece, mas tem alta probabilidade de interesse. Outra categoria é a baseada em conteúdo, na qual os conteúdos apresentados ao usuário são baseados nas suas próprias preferências, mas considerando as características de determinado item de interesse. Por fim, existe a abordagem híbrida, em que ambas as categorias citadas são mescladas, aproveitamento, desse modo, as melhores funcionalidades de cada uma (THOMAS; SUJATHA, 2016). As aplicações de sistemas de recomendação são adotadas nos mais diversos campos, entre eles, plataformas de *streaming* de filmes e séries, sites de vendas *online* entre outros. Ainda assim, os sistemas de recomendação vêm recebendo novas propostas de uso, como sistemas aptos a propor pontos de carga para condutores de carros elétricos (FERREIRA et al., 2011), notícias personalizadas (YEUNG; YANG, 2010) e sistemas focados em acessibilidade (CARDOSO et al., 2016).

1.1 PROBLEMÁTICA

Os ambientes inteligentes, através da Internet das Coisas, tornam possível a interação entre usuários e a tecnologia. No entanto, há dispositivos que ainda não fazem uso de todo o potencial proporcionado através da IoT para fornecer experiências como os objetos presentes em casas inteligentes, entre eles, geladeiras, fogões etc.

Em relação às geladeiras inteligentes, um dos problemas em aberto está o modo com o qual é realizado o monitoramento e registro de itens. Muitas propostas fazem uso de dispositivos que operam por ondas eletromagnéticas. No entanto, os alimentos que contém água além de estruturas metálicas podem interferir no desempenho das leituras a depender da tecnologia utilizada (PERIYASAMY; DHANASEKARAN, 2015; QING; CHEN, 2007). Por outro lado, os métodos que utilizam processamento de imagem têm êxito em monitoramento de alimentos naturais como verduras e frutas (SHWETA, 2017), mas não há propostas que englobe processamento de imagem para produtos embalados, como leite, enlatados entre outros na literatura.

Apesar do grande número de estudos a cerca da IoT, as tecno-

logias e aplicações propostas não têm demonstrado a devida atenção aos aspectos de usabilidade e experiência do usuário, focando mais no ponto de vista técnico (KORESHOFF; ROBERTSON; LEONG, 2013). É necessário, portanto, incluir no projeto de aplicações conceitos que visem auxiliar o ser humano no seu dia a dia.

Desse modo, tem-se como pergunta de pesquisa: “Como aprimorar o conceito atual de geladeira levando em conta a interação dos usuários de modo que o dia a dia destes seja facilitado?”

1.2 OBJETIVOS

Esta seção apresenta o objetivo geral e os objetivos específicos do trabalho.

1.2.1 Geral

Desenvolver um modelo de geladeira inteligente que facilite o dia a dia dos usuários a partir da análise das interações destes.

1.2.2 Específicos

- Elaborar e desenvolver um projeto de leitura e monitoramento dos produtos contidos na geladeira.
- Implementar um sistema de análise das interações e recomendação de produtos.
- Elaborar um cenário que permita a avaliação do modelo proposto.
- Avaliar e discutir os resultados obtidos a partir do sistema proposto.

1.3 JUSTIFICATIVA E MOTIVAÇÃO

A Internet tem evoluído nas últimas décadas impactando na economia mundial e no dia a dia das pessoas. Nos seus primeiros anos de existência, tinha como principal função o uso militar e acadêmico, como foco em troca de informações (LEINER et al., 2012). Contudo, anos mais tarde foi aberta para uso da população em geral permitindo, desse modo, que pessoas comuns tivessem acesso a rede. Hoje, cerca de me-

tade da população mundial usa a Internet frequentemente (MINIWATTS MARKETING GROUP, 2016).

No cenário atual, um novo grupo está sendo conectado na Internet: "as coisas". Cria-se um novo paradigma, a Internet das Coisas, onde a rede não será mais utilizada apenas da maneira tradicional, como em um computador de mesa ou *smartphone* entre outros, mas por dispositivos que possuem acesso a redes e capacidades como sensoriamento, atuação e comunicação com outros dispositivos. Muitos dos dispositivos serão versões conectadas dos objetos presentes no dia a dia, como televisão, fogão, geladeira, lâmpada e porta. Todos esses equipamentos, operando em conjunto com a rede, criarão um ecossistema de objetos com funcionalidades inéditas.

Com a IoT estima-se que até 2020, cerca de 24 bilhões de dispositivos estejam conectados, garantindo espaço para inovação em produtos e serviços. Além disso, espera-se que a Internet das Coisas se torne um grande atrativo para o mercado. Preve-se que, em 2025, sejam gerados em torno de 13 trilhões de dólares (MEOLA, 2016).

A sociedade se beneficia com o desenvolvimento da Internet das Coisas. As soluções geradas considerando este conceito trarão novas formas de interação entre as pessoas e os objetos que as cercam no cotidiano. Ambientes como casa, indústria e sala de aula terão a disposição novas formas de interação a partir da tecnologia.

Tratando-se de uma casa inteligente, chamada também de *smart home*, os moradores tem a disposição conforto e comodidade em virtude dos objetos conectados presentes nela, entre eles a geladeira. Presente em grande parte dos lares, o refrigerador tem um papel fundamental na vida dos moradores. Os alimentos contidos nele devem ser bem conservados para o consumo. No entanto, produtos são esquecidos no seu interior e, por vezes, passam do prazo de validade. Além disso, seria cômodo aos usuários, estando em um supermercado, se soubessem quais itens estão faltando ou vencidos, evitando assim compras desnecessárias. Apesar da facilidade na visita ao supermercado com uma lista em tempo real dos produtos necessários, seria ainda mais cômodo se o refrigerador automaticamente realiza-se compras de itens essenciais como leite ou carne e o supermercado entregasse as compras em casa. Ainda que tais funcionalidades não sejam comuns, existem propostas de geladeiras inteligentes que as implementam. Contudo, não há abordagens em que se leve em conta os interesses do usuários como preferências por certos alimentos, horários em que o consumo é mais comum, a sugestão de itens similares quando os rotineiramente comprados se encontram em falta, a recomendação de receitas com os

produtos disponíveis, entre outros. Por isso, acredite-se que entender o comportamento dos usuários por meio da IoT pode facilitar o dia a dia destes.

Portanto, este trabalho trará como contribuição a melhora do modelo atual de geladeira inteligente leve em conta os interesses e padrões de consumo de seus usuários.


1.4 PROCEDIMENTOS METODOLÓGICOS

Um método representa a ordem que se deve impor aos diferentes procedimentos necessários para atingir um certo objetivo (CERVO; BERVIAN; SILVA, 2007). Por meio destes procedimentos, a pesquisa caracteriza-se como uma atividade voltada para a investigação de problemas teóricos ou práticos (MATIAS-PEREIRA, 2012).

Este trabalho pode ser caracterizado, quanto à sua finalidade, como uma pesquisa aplicada, visto que, conforme Matias-Pereira (2012), “os conhecimentos adquiridos são utilizados para aplicação prática e voltados para a solução de problemas concretos da vida moderna”. Quanto ao objeto, o projeto é descrito como uma pesquisa bibliográfica, já que é necessário o levantamento do estado da arte do tema, fundamentação teórica e definição da contribuição do trabalho (MATIAS-PEREIRA, 2012). De acordo com a modalidade, a pesquisa se identifica como uma pesquisa tecnológica, onde será criado um artefato tecnológico, sendo este um protótipo de geladeira capaz de reconhecer as interações do usuário, realizar compras automáticas além de recomendações de outros produtos e receitas com base nas preferências do usuário.

A metodologia de desenvolvimento deste trabalho é dividida em 8 etapas, das quais, a ordem cronológica é apresentada na Figura 1.1.

Figura 1.1 – Fluxo das Etapas do Trabalho



A seguir, a sequência de etapas demonstradas anteriormente são especificadas em detalhes.

- Etapa 1: Análise e definição do escopo do trabalho.
- Etapa 2: Levantamento bibliográfico sobre Internet das Coisas e Sistemas de Recomendação;
- Etapa 3: Elaboração e desenvolvimento de um projeto de leitura e monitoramento dos produtos contidos na geladeira.
- Etapa 4: Implementação de um sistema de análise das interações e recomendação de serviços.
- Etapa 5: Desenvolvimento de um protótipo funcional que integre as Etapas 3 e 4.
- Etapa 6: Criação de um cenário de testes para avaliar o protótipo.
- Etapa 7: Avaliação e discussão dos resultados obtidos no cenário proposto.
- Etapa 8: Escrita do Trabalho de Conclusão de Curso.

1.5 ORGANIZAÇÃO DO TRABALHO

Este trabalho, até o momento visando cumprir os requisitos da etapa etapa do TCC I, é dividido em cinco capítulos. O **Capítulo 1** apresenta uma introdução do estado da arte das áreas envolvidas bem como a problemática do trabalho e os objetivos gerais e específicos.

O **Capítulo 2** trata da Internet das Coisas, no qual é realizada uma revisão da arquitetura para organização dos diversos componentes, das tecnologias existentes que possibilitam o desenvolvimento de novos dispositivos e, por fim, uma descrição sobre alguns dos ambientes nos quais a Internet das Coisas será incorporada nos próximos anos.

O **Capítulo 3** apresenta a área de Sistemas de Recomendação considerando um histórico, as principais abordagens e aplicações em que esta se insere.

O **Capítulo 4** tem por objetivo detalhar o sistema proposto apresentando uma visão lógica e uma visão física promovendo assim um entendimento do como os diversos componentes interagem e se comportam.

O **Capítulo 5** apresenta o cronograma necessário para o cumprimento de todas as etapas necessárias para finalizar este trabalho.

2 INTERNET DAS COISAS

A tecnologia, com o passar dos anos, está cada vez mais presente nas indústrias, lares, comércios etc., ao mesmo tempo tornando-se indispensável para todas essas entidades. No entanto, nos últimos anos um novo paradigma está emergindo: a Internet das Coisas. A partir dela, a Internet vai deixar de existir como é vista hoje tornando, assim, onipresente (citar).

O conceito de Internet das Coisas (IoT) está relacionado à interconexão de objetos distintos através de uma rede, sendo esta, muitas vezes, a Internet. Desse modo, elementos do mundo real, que antes funcionavam de maneira independente ao meio aos quais estavam inseridos, são capazes de interagir com outros objetos à sua volta e, assim, trocar informações que possam ser relevantes permitindo a agregação de novas funcionalidades. Além disso, a IoT abre espaço para interação entre o mundo físico e o digital a partir de dispositivos capazes de capturar dados físicos no meio em que estão tais como, temperatura, distância etc., representá-los digitalmente e transmitir-los para outros dispositivos.

O termo “Internet das Coisas” foi citado pela primeira vez por Kevin Ashton, diretor executivo da AutoIDCentre do MIT, em 1999 enquanto realizava uma apresentação para promover a ideia do uso de Identificadores de Radio Frequência (RFID) na etiquetagem de produtos. O uso da tecnologia beneficiaria a logística da cadeia de produção (FINEP, 2015). Apesar de o termo IoT ter sido usado apenas em 1999, aplicações práticas da ideia já existiam anos antes. Um exemplo disso, é a torradeira que podia ser ligada e desligada via internet criada em 1990 (SURESH et al., 2014).

A Internet das Coisas está em grande expansão. Estima-se que em 2020 cerca de 24 bilhões de dispositivos IoT estejam conectados, implicando em cerca de quatro dispositivos por pessoa. Para tanto, em torno de 6 trilhões de dólares serão investidos em desenvolvimento de tecnologias de hardware e software, como aplicações, segurança e dispositivos de hardware. Apesar da grande quantia investida, o setor é visto como promissor. Estima-se será gerado em torno de 13 trilhões de dólares em 2025 (MEOLA, 2016).

2.1 ARQUITETURA

Segundo Al-Fuqaha et al. (2015), para que seja possível a Internet das Coisas, em meio ao grande número de objetos, são necessários seis elementos básicos: identificação de cada dispositivo na rede, sensoriamento sobre o ambiente, comunicação entre os dispositivos e a Internet, computação, serviços e semântica. As arquiteturas para Internet das Coisas, devem levar em conta esses pontos.

Ao longo dos últimos anos, alguns modelos de arquiteturas foram propostos no âmbito da Internet das Coisas. Al-Fuqaha et al. (2015) em seu trabalho, mostra algumas das arquiteturas mais comuns para IoT, entre elas, as que estão mostradas na Figura 2.1.

Figura 2.1 – Arquiteturas para IoT



Fonte: Adaptado de Al-Fuqaha et al. (2015)

A arquitetura em três camadas pode ser definida como a base para dispositivos relacionados à IoT e envolve a percepção, a rede e a aplicação. A primeira camada compreende os objetos inteligentes dotados de sensoriamento e atuação sobre o ambiente, já a segunda se refere a infraestrutura de comunicação responsável por conectar os dispositivos entre si e com a Internet e, por fim, a camada de aplicação provê serviços, processamento e tomada de decisão.

Neste trabalho, será feito uso da arquitetura de cinco camadas,

sendo que a primeira camada é responsável por comportar os objetos dotados de sensoriamento e/ou atuação, pelos quais, interagem diretamente com o ambiente. Já a segunda camada, é responsável por transmitir de forma segura os dados provenientes da camada anterior. A camada de gerenciamento de serviços atua como intermediária entre requisitores de serviços e provedores, além de processar os dados da camada inferior e entregar devidos serviços de acordo com o necessário. O quarto nível interage diretamente com os usuários a partir do fornecimento de serviços como exibição de informações de sensoriamento, além do controle sobre atuadores. Já a última camada é responsável por gerenciar todas as atividades e serviços da IoT, além de possibilitar a tomada de decisão e análise de *big data* a partir dos dados provenientes da camada de aplicação (AL-FUQAHA et al., 2015).

2.2 TECNOLOGIAS

Para compreender melhor a funcionamento e a evolução da Internet das Coisas, é importante ter conhecimento e entendimento das tecnologias que dão base a ela. As principais tecnologias necessárias estão imersas nas camadas das arquiteturas expostas na seção anterior, ou seja, sensoriamento e atuação, redes e aplicação. A seguir, uma breve introdução em algumas das tecnologias é exposta.

2.2.1 Bluetooth

O Bluetooth é uma especificação de rede *Wireless Personal Area Network* (WPAN)¹, ou seja, rede sem-fio pessoal, sendo descrito e especificado pelo padrão definido pela *Institute of Electrical and Electronics Engineers* (IEEE)², o IEEE 802.15.1. O Bluetooth foi criado na década de 90 com o objetivo de unir tecnologias distintas, tais como computadores, celulares entre outros a partir de uma padronização de comunicação sem fio entre os dispositivos (KARDACH, 2008). Uma das principais características dessa tecnologia *wireless* é o curto alcance de transmissão variando de centímetros até alguns metros (HUANG; RUDOLPH, 2007).

No IEEE 802.15.1 há suporte para criação de redes *ad-hoc*, aos quais, é desnecessário uma infraestrutura de rede para conexão dos dis-

¹Traduzido como: Rede Sem Fio de Área Pessoal.

²Traduzido como: Instituto de Engenheiros Eletricistas e Eletrônicos.

positivos. A partir disso é possível criar redes chamadas *picorredes*, nas quais os dispositivos são organizados em até oito associados, sendo um deles um mestre, ao qual coordena as operações, e os demais escravos (BLUETOOTH SIG, 2017c).

A tecnologia Bluetooth opera na *Industrial Scientific and Medical* (ISM)³ de 2.4 GHz de uso livre em modo *Time-Division Multiplexing* (TDM)⁴ com um delta de $625\mu\text{s}$, proporcionando uma taxa de transmissão máxima em torno de 2 Mb/s, podendo variar de acordo com o dispositivo e a categoria de tecnologia de Bluetooth utilizada (BLUETOOTH SIG, 2017c).

2.2.1.1 Categorias

Segundo BLUETOOTH SIG, o Bluetooth pode ser categorizado em:

(A) *Basic Rate/Enhanced Data Rate* (BR/EDR)⁵

Esta é a subdivisão mais popularizada do Bluetooth presente nas versões 2.0 e 2.1, onde as principais características são alta velocidade de transmissão alta, baixo alcance e necessidade de conexão através de pareamento, onde os dispositivos devem confirmar a conexão. A partir disso, há uma transmissão contínua de dados. Uma desvantagem é o consumo de energia considerável para o funcionamento do Bluetooth, já que há uma conexão contínua e uma taxa de transmissão que mantém o dispositivo ativo por um longo período ininterrupto. A taxa de transmissão gira em torno de 2Mb/s.

(B) *Bluetooth Low Energy* (BLE)⁶

O BLE é a mais recente categoria do Bluetooth incorporada na versão 4.0, em 2011, além de ser a menos comum (LABS, 2015). BLE está centrado no baixo consumo de energia para permitir que certos dispositivos não precisem recarregar ou trocar suas fontes de energia, geralmente baterias, por longos períodos, que podem chegar a anos. Para uma conexão para transmissão de dados, ao contrário do BR/EDR, não é necessário um pareamento para realizá-la, além disso esta tem curta duração, na ordem de

³Traduzido como: Industrial Científico e Médico.

⁴Traduzido como: Multiplexação por Divisão de Tempo.

⁵Traduzido como: Taxa Básica / Taxa de Dados Aprimorada.

⁶Traduzido como: Bluetooth de Baixo Consumo Energético.

milissegundos. Ademais, a taxa de dados é baixa e o alcance alto. A baixa taxa de dados decorre do modo de funcionamento dos dispositivos BLE, aos quais, enviam dados em rajadas, ou seja, de tempos em tempos dados são transmitidos em forma de *broadcast* e os dispositivos que estiverem conectados receberão esses dados. Nos intervalos de tempo em que o dispositivo não transmite, ele “dorme”, isto é, entra em modo de consumo mínimo a fim de poupar energia.

A aplicação prática dessas características está na IoT através de *beacons* e *wearables*, aos quais incorporam o BLE. Os beacons foram introduzidos pela *Apple* em conjunto com o iOS 7, com o nome de *iBeacon*, que permitia aos aplicativos possuírem senso de localização (APPLE, 2014). Com esses dispositivos é possível aprimorar a experiência do usuário em estabelecimentos como museus, supermercados, shoppings, estádios, através da identificação de contexto, na qual, com base na detecção de um beacon e da aproximação ou afastamento deste, uma aplicação móvel em um smartphone de um usuário pode exibir conteúdos, indicar promoções entre outros relacionados aquele dispositivo BLE.

(C) Dual-mode

Esta categoria se refere a dispositivos, como *smartphones* que precisam se conectar tanto com dispositivos BR/EDR, como fones de ouvido, e BLE, como *beacons* (BLUETOOTH SIG, 2017b).

2.2.1.2 Bluetooth 5.0

A versão 5.0 do Bluetooth foi lançada em dezembro de 2016 e trás consigo aprimoramentos em desempenho e segurança, garantindo duas vezes mais velocidade, quatro vezes mais alcance, oito vezes mais taxa de dados e, por fim, maior coexistência (BLUETOOTH SIG, 2017a).

Com a nova versão, veio a flexibilidade para construção de soluções baseadas em necessidade. Parâmetros como alcance, velocidade e segurança podem ser regulados para diversos objetivos a depender das aplicações (BLUETOOTH SIG, 2017a).

Algumas atualizações contribuem para a redução de interferência com outras tecnologias sem fio, dessa forma, proporciona melhor coexistência entre dispositivos Bluetooth e de outras tecnologias, dentro do cenário emergente da IoT (BLUETOOTH SIG, 2017a).

2.2.2 RFID

O protocolo de *Radio-Frequency IDentification* (RFID)⁷ é uma tecnologia de identificação automática, entre diversas outras como código de barras, cartão inteligente e procedimentos biométricos, no entanto se distingue pelo modo de funcionamento, ou seja, por ondas eletromagnéticas. Além disso, o RFID se destaca em relação às outras tecnologias no que se refere às influências externas no seu funcionamento, como sujeira, posição de leitura. Desse modo, não é necessário nem limpar ou reposicionar o dispositivo RFID para efetuar a leitura (FINKENZELLER, 2010).

No RFID, os dados são transmitidos através de ondas de rádio entre dois dispositivos: *transponder* ou *tag* e *leitor*. O transponder é localizado no objeto identificado, um produto, equipamento etc., e nele são mantidos os dados de identificação. Já o leitor é responsável pela leitura e escrita dos dados presentes no transponder (FINKENZELLER, 2010). Para a transmissão dos dados entre os dois dispositivos o leitor emite ondas de rádio na tag. Ao receber o estímulo, a tag responde com os dados contidos nela. Além disso, existem tags que utilizam a energia do campo eletromagnético gerado pelo leitor para seu funcionamento, sendo estas chamadas de *passivas*. Existem, também, aquelas que possuem uma fonte própria de energia e por isso são denominadas *ativas* (FINKENZELLER, 2010).

Uma das características mais importantes dos dispositivos RFID é a frequência de operação. Os dispositivos são classificados, de acordo com esse parâmetro, em três grupos:

- **LF (Baixa Frequência):** Entre 30kHz à 300kHz
- **HF (Alta Frequência):** Entre 3MHz à 30MHz
- **UHF (Ultra Alta Frequência):** Entre 300MHz a 3GHz.

É possível distinguir pelo alcance:

- **Long-range ou longo alcance:** maior que um metro
- **Remote-coupling ou ligação remota:** até um metro
- **Close-coupling ou ligação próxima:** até um centímetro

⁷Traduzido como: Identificação por Rádio Frequência.

2.2.3 NFC

O *Near Field Communication* (NFC)⁸ é um sistema de comunicação sem fio derivado do RFID. Ele permite transações simples e seguras entre dois dispositivos a partir da curta distância de operação, em torno de 4cm, e do funcionamento baseado em aproximação dos objetos em questão (NFC FORUM, 2016a). Assim, é possível realizar leituras de tags e obter conteúdos de acordo com a aplicação, transferir dados entre smartphones entre outras funcionalidades. Outra vantagem do NFC é a compatibilidade com a infraestrutura de cartões sem contato existentes permitindo usar um único dispositivo em tecnologias diferentes. Desse modo, é possível interagir com tags RFID, por exemplo.

Como o RFID, o NFC funciona através de ondas eletromagnéticas, mas com uma taxa de transmissão máxima de 424 kbps (NFC FORUM, 2016a). Além disso, pode operar em dois modos de comunicação: ativo e passivo (IGOE; COLEMAN; JEPSON, 2014). Assim como no RFID, é possível que os dispositivos NFC que contenham os dados usem a energia do leitor para transmitir seus dados, no modo passivo, ou usem uma fonte própria para tal procedimento, no modo ativo.

Outra característica importante no NFC são os modos de operação. De acordo com NFC Forum (2016a) existem três modos:

- **Leitor/Escritor de tag:** Tem por objetivo ligar o mundo físico ao digital através de aplicações que leem e/ou escrevem em tags para obter dados e, assim, fornecer conteúdo ao usuário relacionado à tag lida. Um exemplo é um smartphone ao ler uma tag NFC de um cartaz na rua.
- **Peer to Peer:** Visa conectar dispositivos por aproximação física e permite transferência de dados. Um exemplo é o Android Beam⁹ que permite troca de arquivos entre smartphones com o sistema operacional móvel da Google.
- **Emulação de cartão:** Conecta o dispositivo do usuário em uma infraestrutura possibilitando a simulação de um cartão, além da realização de transações financeiras e identificação no sistema de transporte a partir da aproximação do dispositivo a um leitor específico.

Há quatros tipos de tags definidas (NFC FORUM, 2016b), sendo

⁸Traduzido como: Comunicação por Campo de Proximidade.

⁹https://www.android.com/intl/pt-BR_br/

que todos operam no modo Leitor/Escritor descrito anteriorente :

- **Tipo 1:** 96 bytes de memória disponível e expansível para 2kiB. Usuário pode configurá-la para somente leitura.
- **Tipo 2:** 48 bytes de memória disponível e expansível para 2kiB. Usuário pode configurá-la para somente leitura.
- **Tipo 3:** Baseado no padrão industrial japonês e conhecido como FeliCa. Pode ser configuradas para leitura/escrita ou somente leitura na fabricação. A memória disponível varia, mas com um limite teórico de 1MiB.
- **Tipo 4:** A memória disponível varia estando acima de 35 kiB por serviço. É possível ser configurada para leitura/escrita ou somente leitura.

O NFC possui um padrão com o qual dispositivos devem estar formatados, o *NFC Data Exchange Format* (NDEF)¹⁰ (*NFC Data Exchange Format*) um formato comum de comunicação (IGOE; COLEMAN; JEPSON, 2014). Desse modo, os dados armazenados em tags devem estar gravados nesse formato. A partir do NDEF é possível armazenar e trocar documentos binários como Mime, que incluem imagens, arquivos *Portable Document Format* (PDF)¹¹ entre outros, *Uniform Resource Locator* (URL)¹², texto simples entre outros.

2.2.4 Zigbee

O Zigbee é um protocolo padrão de comunicação de baixa potência para redes sem-fio *mesh*, ao qual permite a diversos dispositivo trabalharem em conjunto (FALUDI, 2011). Além disso, é descrito como um conjunto de camadas implementadas sobre o IEEE 802.15.4 (FALUDI, 2011), ao qual especifica a camada física (PHY) e o controle de acesso ao meio (MAC) para redes sem-fio de baixa potência (IEEE, 2011).

As camadas do Zigbee, de acordo com Faludi (2011), fazem:

- **Roteamento:** Tabelas de roteamento que definem como um nó envia dados até um destino.
- **Rede Adhoc:** Criação automática de rede.

¹⁰Traduzido como: Formato de Troca de Dados por NFC.

¹¹Traduzido como: Formato de Documento Portátil.

¹²Traduzido como: Localização Uniforme de Recursos.

- ***Self healing mesh***: Descobre se nós se perderam da rede e a re-configura para garantir uma rota para os dispositivos conectados ao nó faltantes.

O Zigbee opera na faixa não licenciada ISM, de 2,4GHz, o que permite sua expansão global e, assim, ser capaz de operar em qualquer local do mundo. Além disso, especifica que os nós das redes criadas possam assumir papéis específicos. Cada nó deve assumir uma das categorias a seguir (FALUDI, 2011):

- **Coordenador**: Responsável por criar a rede, distribuir endereços, manter a rede segura e em funcionamento entre outras funções. Por fim, cada rede tem um e apenas um coordenador.
- **Roteador**: Tem capacidade de unir redes existentes, enviar e receber informações e rotear informações, atuando como um intermediário entre dispositivos que, por estarem muito distantes entre si, não podem se comunicar diretamente. É permitido às redes terem múltiplos roteadores, podendo também não possuírem nenhum, no entanto no caso de existirem, cada roteador deve estar conectado a um coordenador ou outro roteador.
- **Dispositivo final**: É um tipo de nó capaz de se unir a redes e de enviar e receber informações da rede. Além disso, podem se desligar de tempos em tempos para poupar energia. Caso mensagens para um dispositivo final desligado sejam detectadas, o nó responsável por ele, podendo ser um coordenador ou roteador, armazena as mensagens até que o nó desperte.

Há diversas topologias suportadas, nas quais, englobam os três tipos de nós e suas possíveis maneiras de organização (FALUDI, 2011):

- **Par a par**: Uma rede formada apenas por dois nós, sendo um deles, obrigatoriamente, um coordenador e nó restante podendo ser um roteador ou dispositivo final.
- **Estrela**: Nessa topologia, o coordenador se situa no centro da rede e os demais nós, roteadores ou dispositivos finais, conectados apenas a ele, formando uma rede no formato de estrela.
- **Mesh**: Os dispositivos finais circundam os demais nós roteadores e coordenador. O coordenador e roteadores atuam como intermediários, roteando mensagens para dispositivos finais, outros roteadores ou para o coordenador. Apesar da nova função do coordenador, este permanece no controle e gerenciamento da rede.

- **Cluster tree:** Nessa topologia, cada roteador é responsável por um conjunto de dispositivos finais. As mensagens vindas desses dispositivos devem ser encaminhadas primeiramente para seu roteador responsável para então ser encaminhada ao destino na rede.

O Zigbee define três maneiras de identificação de nodos, que podem utilizadas em uma aplicação para diferenciar os nós.

- **64 bits:** Único e permanente para cada rádio fabricado.
- **16 bits:** Dinamicamente configurado pelo coordenador ao entrar em uma rede. É único apenas dentro do contexto da rede.
- **Node Id:** Pequena cadeia de texto. Não é possível garantir sua unicidade em nenhum contexto, apesar disso, é mais amigável aos olhos humanos.

2.2.5 Wi-Fi

Wi-Fi, é uma das diversas classes de *Wireless Local Area Network* (WLAN)¹³ normatizado pelo padrão IEEE 802.11, no qual foca nas camadas física e de enlace do modelo *Open System Interconnection* (OSI)¹⁴ (GAST, 2005). Além disso, há padrões específicos para o Wi-Fi, como o 802.11a, 802.11b e 802.11g, além da possibilidade de unir alguns de padrões para formar outros híbridos, como o 802.11a/g e 802.11a/b/g (KUROSE; ROSS, 2012).

Apesar da distinção, os padrões citados compartilham diversas características, como o protocolo de acesso ao meio, estrutura de quadros da camada de enlace, habilidade de reduzir a taxa de transmissão a fim de alcançar distâncias maiores. A principal diferença é vinculada à camada física.

Os padrões a, b e g são regulamentados de acordo com a Tabela 2.1, sendo que pode variar em diversos países.

Além dos três protocolos citados há outros mais recentes ou que estão em fase de criação. O protocolo 802.11n, por exemplo, criado em 2012, faz uso de múltiplas antenas e, além disso, permite atingir uma taxa de transmissão de centenas de megabits por segundo. (KUROSE; ROSS, 2012).

A arquitetura básica do IEEE 802.11, exposta na Figura 2.2, é formada por *Basic Service Set* (BSS)¹⁵ onde cada um é composto de

¹³Traduzido como: Rede Local Sem Fio.

¹⁴Traduzido como: Conexão de Sistema Aberta.

¹⁵Traduzido como: Conjunto Básicos de Serviço.


Tabela 2.1 – Resumo dos protocolos 802.11

Padrão	Faixa de Frequências	Taxa de dados
802.11b	2,4 - 2,485 GHz	até 11 Mbps
802.11a	5,1 - 5,8 GHz	até 54 Mbps
802.11g	2,4 - 2,485 GHz	até 54 Mbps

Adaptado de: Kurose e Ross (2012)

um Ponto de Acesso (AP), um dispositivo para unir os conjuntos, sendo esse um roteador ou *switch*, responsável por ligar cada BSS à Internet e, por fim, os dispositivos que desejam se conectar a rede.

Figura 2.2 – Arquitetura básica para o IEEE802.11.



Fonte: Kurose e Ross (2012).

O IEEE 802.11 suporta dois tipos de interconexão de dispositivos: *ad-hoc* e ponto de acesso com dispositivo. No primeiro caso, é possível interconectar dispositivos, como notebooks, sem a necessidade de uma infraestrutura de rede, no entanto com a impossibilidade de conexão com a Internet, apenas com os dispositivos na rede. Assim, é possível efetuar transferência de arquivos de maneira rápida e sem cabos. Além de redes *ad-hoc*, suporta conexões entre um ponto de acesso e um dispositivo para conexão com a Internet. Em diversos casos, o AP e o roteador estarão incorporados em um mesmo dispositivo (KUROSE; ROSS, 2012).

Existem algumas funcionalidades mais avançadas no IEEE 802.11. Uma delas se refere à possibilidade de se adaptar a taxa de dados a partir da escolha da técnica de modulação da camada física de acordo com

as características do canal. Há também a possibilidade de reduzir o consumo de energia a partir fazendo com que o nó em modo *sleep* por determinados períodos de tempo o que pode gerar uma economia de até 99% (KUROSE; ROSS, 2012).

No contexto da Internet das Coisas, o Wi-fi é fundamental na inserção de novos dispositivos conectados à Internet. O seu uso, consideravelmente difundido, facilitará o alcance de novos dispositivos à rede e propiciará o crescimento destes sem a necessidade da expansão da infraestrutura a cada novo objeto conectado (SURESH et al., 2014).

2.2.6 Outros

Entre as tecnologias utilizadas em Smart Homes está o Z-Wave, um protocolo sem fio focado em automação residencial e comercial de pequeno porte, criado pelo ZenSys e hoje representado pela Z-Wave Alliance (GOMEZ; PARADELLS, 2010). O protocolo foi desenvolvido especificamente para controle, monitoramento e verificação de estado. Em relação a aspectos técnicos, o Z-Wave opera na faixa de frequências em torno de 1GHz, o que evita interferências com outras tecnologias como Bluetooth e Wi-Fi que operam em 2,4GHz, em geral. Entre as principais vantagens do Z-Wave está a interoperabilidade que este proporciona entre os diversos produtos desenvolvidos com a tecnologia, além da segurança obtida a partir do uso de criptografia AES128 (Z-WAVE ALLIANCE, 2015).

Por outro lado, há a tendência de dispositivos IoT conectados à Internet usarem o protocolo de endereçamento IPv6 para serem identificados na rede. No entanto, algumas das aplicações terão limitações como fonte de energia e capacidade de transferências de dados limitadas. Como proposta de solução, tem-se o 6LoWPan, definido no RFC 6282 pela Internet Engineering Task Force (IETF) focado em dispositivos com restrições de consumo de energia (OLSSON, 2014). A principal característica desse protocolo é a redução da transmissão de dados a partir da compressão dos cabeçalhos do IPv6. Com isso, o 6LoWPan é capaz de reduzir a sobrecarga de pacote para dois bytes (AL-FUQAHA et al., 2015). As redes 6LoWPAN são conectadas às redes IPv6 a partir de roteadores de borda, capazes de trocar dados entre os dispositivos dentro da rede 6LoWPAN e a Internet e entre os dispositivos da rede além de ser responsáveis por manter a rede em funcionamento. Outra característica importante nesse padrão é que este torna possível implementar o IPv6 em redes IEEE 802.15.4 (OLSSON, 2014).

2.3 AMBIENTES INTELIGENTES

A Internet das Coisas trará tecnologia para ambientes e, assim, aprimorará as funcionalidades existentes além de trazer novas, proporcionando eficiência e qualidade. A seguir, alguns ambientes em destaque são expostos e como a Internet das Coisas atua nestes casos.

2.3.1 Smart grid

Na rede elétrica tradicional, a inteligência é concentrada nas unidades geradoras de energia e parcialmente nos distribuidores e o fluxo de energia é unidirecional, seguindo apenas um caminho entre a geração e o consumo. No entanto, com o aumento do uso de fontes próprias geração de energia como placas fotovoltaicas em residências, além do crescimento do consumo tem-se a necessidade de adaptação do modelo de rede elétrica existente. As *smart grids* surgiram, então, como novo modelo de geração e distribuição de energia elétrica, onde o fluxo de energia passa a ser bidirecional e o uso de tecnologias de medições de consumo permitem prever demandas, otimizar a distribuição e aprimorar a eficiência e a confiabilidade do sistema elétrico (CECILIA; SUDARSANAN, 2016). Portanto, a smart grid tenderá a ser um avanço do modelo atual com o uso de tecnologias de comunicação, sistema eletrônicos de potência avançados e de medição o que possibilitará monitoramento em tempo real, permitindo o fluxo de informações em ambos os sentidos entre consumidores e unidades geradores além da garantia de otimização do fluxo de energia.

2.3.2 Smart home

O conceito de *smart home* ou casa inteligente propõe um novo modelo para um ambiente domiciliar no qual a implementação e o uso da tecnologia abrem espaço para novas formas de interação com o lar, além de proporcionar mais comodidade e um melhor gerenciamento dos equipamentos presentes. Isso será possível graças ao uso de sensores e atuadores no ambiente, nos eletrodomésticos e utensílios. E, para interconectar todos os dispositivos, fará-se o uso das tecnologias de rede existentes, como o Zigbee e a Internet. Além disso, a interconexão dos dispositivos em uma casa inteligente proporcionará funcionalidades inéditas de interação de acordo com as ações do morador, como entrar


e sair de um cômodo da casa. Nesse caso, seria possível implementar um sistema que apagasse e acendesse a lâmpada conforme os sensores de presença indicarem a ausência do indivíduo e a hora do dia (SILVA et al., 2012).

Entre as apostas para as casas inteligentes está o aumento da eficiência do consumo energético. O uso da tecnologia por meio de medidores de energia, tomadas e aparelhos inteligentes permitirá o monitoramento e controle do consumo dos dispositivos da casa. Com base nisso, é viável a otimização do consumo de cada equipamento controlando-o para ativá-lo somente quando necessário e, assim, evitar desperdícios, além de previsão da demanda de energia para cada momento do dia (STOJKOSKA et al., 2017).

As casas inteligentes necessitam que os dispositivos sejam organizados hierarquicamente para garantir o bom desempenho dos componentes do sistema. Stojkoska et al. (2017) propõe um modelo, mostrado na Figura 2.3 para organização de casa inteligente que integra *smart grid* e envolve cinco componentes principais: a casa inteligente em si, a nuvem, unidade geradora de energia, aplicações de terceiros e interfaces de usuário. Nesse contexto, a casa inteligente contém redes de sensores sem fio que adquirem dados do ambiente e enviam esses dados para um *home hub*, um ponto central capaz de se conectar à uma rede externa. Já a unidade geradora de energia é responsável por, além da geração e fornecimento de energia, trocar informações sobre custo da energia, consumo atual e futuro da casa entre outros. A nuvem é responsável por armazenar todos os dados provenientes de sensores e outros dispositivos da casa e por comportar uma infraestrutura de processamento. A partir dos dados existentes na nuvem é possível que as aplicações de terceiros entreguem soluções web ou aplicações mobile para os usuários. Para obter acesso às soluções, o último componente é necessário, a interface de usuário. Nesse ponto, o usuário tem em mãos a capacidade de monitorar em tempo real os gastos de energia dos equipamentos de sua casa, bem como controlá-los de acordo com a sua necessidade e desejo.

Uma casa inteligente permite que os moradores tenham maior independência no seu dia a dia, especialmente em caso de pessoas idosas, com dificuldade de locomoção, além daquelas com deficiências físicas e visuais. No seu artigo, Silva et al. (2012) propõe um sistema que usa imagens de uma casa, capaz de detectar o dia a dia de uma pessoa idosa. É possível também identificar possíveis quedas e avisar o responsável ou ao atendimento médico. Apesar, da aplicação citada possuir um enfoque no morador, não há muitas propostas para casa inteligente

Figura 2.3 – Modelo para casas inteligentes.



Fonte: Stojkoska et al. (2017).

com o foco nos usuários, no entanto, existem muitas que focam nos aspectos técnicos, como dispositivos, arquiteturas entre outros (WILSON; HARGREAVES; HAUXWELL-BALDWIN, 2015).

Em relação às tecnologias para desenvolvimento de aplicações e dispositivos para casas inteligentes, tem-se diversos sistemas sendo implementados. Entre eles está o projeto *Eclipse SmartHome*¹⁶, ao qual disponibiliza aos desenvolvedores um *framework* para desenvolvimento de soluções casas inteligentes e ambientes assistidos destinadas a usuários finais.

A empresa *Amazon*¹⁷ oferece o *Amazon Echo*, um dispositivo que dispõe de diversas funcionalidades multimídia, como reprodução de músicas através de controle por voz, além de oferecer informações como previsão do tempo, notícias, tráfego entre outros através do *Alexa Voice Service* (Serviço de Voz Alexa). É capaz de controlar a luz, tomadas e termostatos além de ser compatível com produtos de empresas, como

¹⁶<http://www.eclipse.org/smarthome>

¹⁷<https://www.amazon.com/>

SAMSUNG®¹⁸, Philips®¹⁹ entre outras, com foco em *smart homes* (AMAZON, 2017).

Seguindo a lógica das casas inteligentes, as *Smart Kitchens* ou cozinhas inteligentes promovem o aprimoramento dos dispositivos da cozinha com a inserção da tecnologia. A partir disso, utensílios como panelas, talheres entre outros poderão fazer uso de tecnologia para entregar novas funcionalidades (STÄNDER et al., 2012). Por exemplo, no caso das panelas, é possível colocar sensores de temperatura e câmera para determinar a temperatura atual e o estado atual do alimento que está sendo cozido. A partir disso, o sistema computacional presente na panela, processará os dados e fará uma comunicação com o fogão para ajustar a intensidade do fogo caso ainda não esteja pronto, ou simplesmente, desligar o fogo, caso o esteja.

2.3.3 Outros

Entre os ambientes inteligentes em expansão está a cidade inteligente ou *smart city*. Apesar de não ter uma definição conceitual clara (COCCHIA, 2014), no contexto da Internet das Coisas, a ideia principal por trás desse ambiente é trazer qualidade de vida aos cidadãos, crescimento sustentável e melhor uso de recursos públicos, aos quais são possíveis graças ao uso da IoT com foco no ambiente urbano. A Internet das Coisas, nesse contexto, permite uma melhor gerenciamento, otimização dos serviços públicos como transporte, iluminação, vigilância e manutenção de áreas públicas entre outros (ZANELLA et al., 2014).

Já no ambiente industrial, a Internet das Coisas em conjunto com sistemas interconectados promoverá a Indústria 4.0 também chamada quarta revolução industrial. Ademais, os sistemas cyber-físicos, aos quais podem ser definidos como sistemas que integram processos físicos, computacionais, de comunicação e de rede, integrados com a Indústria 4.0, poderão ser definidos como a *smart factory* ou fábrica inteligente (LEE, 2015). Por outro lado, a Indústria 4.0 é vista como possível solução para problemas atuais em indústrias como poluição, consumo de combustíveis fósseis entre outros. Para tanto o uso de tecnologias emergentes para implementar IoT e serviços onde processos de engenharia e de negócios estarão integrados possibilitando produção com qualidade e baixo custo e que seja flexível, eficiente e sustentável

¹⁸<http://www.samsung.com/br/>

¹⁹<http://www.philips.com.br/>

(HUSSAIN, 2016).

2.4 DESAFIOS

Apesar dos avanços constantes, a área de Internet das Coisas terá de superar alguns desafios para que possa se expandir sem prejudicar o desempenho das aplicações e a experiência dos usuários. Esses desafios, segundo Hussain (2016), são a heterogeneidade dos dispositivos, a interoperabilidade, a escalabilidade, segurança, privacidade e Qualidade de Serviço (QoS).

O primeiro dos desafios, a heterogeneidade, se refere as diferenças de hardware e software dos dispositivos bem como seu propósito, como objetivos, plataforma de hardware, modos de interação, entre outros.

A Interoperabilidade diz respeito à capacidade de dispositivos, que usam diferentes tecnologias, poder interagir. Nesses casos é necessário um dispositivo que atue como mediador ao qual tem acesso a ambas tecnologias para que a troca de dados ocorra.

Outro grande desafio é a escalabilidade. As aplicações de IoT devem suportar o crescimento do número de dispositivos conectados, usuários, aplicações entre outros sem qualquer comprometimento da Qualidade de Serviço (QoS). Esse aumento em dispositivos e afins, deve ser refletida nos recursos que sustentam a IoT.

A segurança e privacidade, da mesma forma, requerem atenção. A restrição de recursos torna difícil proteger a informação, ainda assim é necessário garantir transações seguras e o não comprometimento dos dados do usuários. No entanto, os métodos tradicionais não podem ser utilizados, pois diferentes padrões estão envolvidos. Por outro lado, IoT implica em conexão global, ou seja, implica que qualquer indivíduo pode acessar externamente. Portanto, há a necessidade de novos mecanismo que garanta a segurança e privacidade e é importante que os desenvolvedores garantam esses requisitos em suas aplicações.

A Qualidade dos Serviços em IoT vem sendo estudado com frequência. Entre os principais desafios estão disponibilidade, confiabilidade, mobilidade, desempenho, escalabilidade entre outros. No entanto, nem toda a aplicação exige que os pontos citados sejam atendidos integralmente (HUSSAIN, 2016).

3 SISTEMAS DE RECOMENDAÇÃO

A web tem proporcionado diversas formas de interação, seja entre usuários ou entre sistemas e como resultado, tem-se uma grande quantidade de dados gerada. Os usuários que lidam com esses dados brutos certamente terão dificuldades em assimilar alguma informação útil e de seu interesse. Se faz necessário, portanto, um modo de processar tal montante de dados e extrair informações relevantes. Entre os possíveis métodos estão os mecanismos de busca, em relação à páginas web (BRIN; PAGE, 1998), e sistemas de recomendação, em relação a itens .

Sistemas de Recomendação (SRs) surgem então como possível solução, com base na análise do perfil de cada usuário e, a partir deste, fornecer recomendações de itens que possam lhe interessar. Os itens recomendados podem ser filmes, livros, receitas, páginas web entre outros (BOBADILLA et al., 2013). Deste modo, a tarefa de SRs é transformar os dados e preferências dos usuários em previsões de itens aos quais pode-se demonstrar interesse (Lü et al., 2012).

As informações de preferências de usuário, utilizadas como entrada por SRs, podem ser adquiridas de duas maneiras: explícita ou implicitamente. No primeiro caso, o usuário é indagado sobre suas preferências, já no segundo, as informações são extraídas de acordo com o comportamento do usuário e sem o questionamento direto (BOBADILLA et al., 2013). No entanto, informações adicionais podem ser utilizadas (JANNACH et al., 2010). Deste modo, as fontes de informações utilizáveis são: avaliações de itens pelos usuários, conjunto de características específicas que o item deve possuir, além de detalhes sobre seu conteúdo.

Os Sistemas de Recomendação são subdivididos em abordagens, filtragem colaborativa, filtragem baseada em conteúdo, baseada em conhecimento entre outras, às quais diferem na forma como geram sugestões e nas informações que utilizam para tal (JANNACH et al., 2010). No entanto, décadas de pesquisa foram necessárias para resultarem nas abordagens citadas.

3.1 HISTÓRICO

A web primordial ou Web 1.0 era estática, na qual a única perspectiva de interação era o consumo de conteúdo, ou seja, apenas lei-

tura deste se fazia possível. Era, portanto, amplamente utilizada por organizações na divulgação de seus produtos e serviços (AGHAEI; NEMATBAKHSH; FARSANI, 2012).

A Web 2.0, por outro lado, agregou dinamicidade à Internet, desde a viabilização da interação entre usuários e possibilidade de inserção de conteúdo na rede por parte desses, a partir de blogs e redes sociais, por exemplo (NATH; DHAR; BASISHTHA, 2014).

Com a Web 3.0, se deu a transformação da Web de Documentos, presente nas versões anteriores, para a Web de Dados, onde os diversos conteúdos deixam de se relacionar por links e passam a ser por dados e, assim, podem ser utilizados não apenas por usuários, mas por máquinas.

Já se discute a cerca da Web 4.0, apesar de, conceitualmente, não bem definida. Propõe-se que, no futuro, haveria uma simbiose entre os computadores e as pessoas e, como consequência, seria possível a construção de interfaces mais poderosas, entre elas, as controladas pela mente (AGHAEI; NEMATBAKHSH; FARSANI, 2012).

A ideia de fazer uso de todo o volume de dados gerados por muitos usuários, com a Web 2.0, para auxiliar na procura por conteúdos mais úteis e interessantes, já existia desde a década de 1990 (JANNACH et al., 2010).

O primeiro sistema ao qual continha a ideia de recomendação de conteúdo, foi o PARC Tapestry System, que introduziu o conceito de filtragem colaborativa. Ademais, era um sistema experimental de e-mail, onde se objetivava categorizar o grande volume de mensagens eletrônicas recebidas em categorias de acordo com o interesse do usuário (GOLDBERG et al., 1992). Alguns anos mais tarde, o *GoodNews* foi desenvolvido com o foco em notícias, onde cada artigo era avaliado de acordo com a média de avaliações dos usuários e os melhores eram recomendados. Dessa forma, o sistema não levava em conta gostos individuais e eliminava, assim, a necessidade de armazenamento de dados de usuários. Outro sistema desenvolvido, o Ringo, provia recomendações aos seus usuários a cerca de músicas. Inicialmente o utilizador fornecia avaliações de aproximadamente 125 artistas e, de acordo com as respostas era feito uma avaliação do perfil. A aplicação, então, passava a recomendar novos artistas e álbuns que o usuário poderia gostar (RESNICK et al., 1994).

Com o passar dos anos, os Sistemas de Recomendação se expandiram para a área negócios como o comércio eletrônico nos anos 2000 pela Internet. Ademais, se deu uma comercialização imediata e diversas companhias foram criadas como, *Pattie Maes*, *Net Perceptions*,

entre outras. Por outro lado, não apenas pesquisadores apresentaram interesse, mas também profissionais da área de marketing. Por fim, desenvolveu-se novas abordagens baseadas em conceitos de inteligência artificial, recuperação de informação, mineração de dados, segurança, privacidade além de pesquisas em negócios e marketing (JANNACH et al., 2010).

3.2 FILTRAGEM COLABORATIVA (FC)

Em diversas ocasiões do cotidiano as pessoas requisitam opiniões de outras a cerca de certos produtos ou serviços, seja filmes, restaurantes, equipamentos eletrônicos entre outros. A opinião do indivíduo, então, influencia na escolha do outro e o ajuda a tomar uma decisão sobre o problema. Por outro lado, um amigo recomenda a outro que assista um filme de ação em cartaz nos cinemas, sabendo que ainda não assistiu-o e que gosta de filmes do gênero. Esse indivíduo que recebeu a sugestão certamente levará em conta o conselho, assistirá o filme, provavelmente gostará dele e recomendará a um outro amigo que também não viu o filme. Com base nesse contexto de recomendações entre indivíduos, tem-se o conceito de Filtragem Colaborativa (FC), no qual, a partir de um perfil de preferências de um certo indivíduo, obtido através de seu histórico, em conjunto com as opiniões de outros usuários semelhantes a ele, prevê quais os itens que tem a maior possibilidade de gostar ou de se interessar (JANNACH et al., 2010).

Os sistemas baseados em filtragem colaborativa se utilizam da matriz de avaliações de itens pelos usuários, como mostrado na Tabela 3.1. Como saída, gera-se previsões de avaliações que usuários aplicariam para itens por eles não avaliados ou um conjunto de melhores itens para recomendação. Portanto, a partir do conjunto de dados da matriz é possível fazer uso de algoritmos que levem em conta as avaliações de todo o conjunto de usuários, para então definir qual é a avaliação plausível para um determinado item ou quais itens recomendar (BOBADILLA et al., 2013).

Segundo Ricci et al. (2010), os métodos de filtragem colaborativa podem ser agrupados em duas classes: os baseados em memória ou em vizinhança e os métodos baseados em modelo. A principal diferença entre as abordagens está no modo de uso da matriz de avaliações na geração de recomendações.

Tabela 3.1 – Matriz de avaliações de itens por usuários

	Item 1	Item 2	Item 3	Item 4	Item 5	Item 6
Jack	5	4	2	?	5	1
Will	3	5	3	5	1	1
Elizabeth	5	3	3	4	2	4
Hector	3	5	4	5	4	4

Fonte: Autores

3.2.1 Baseado em memória

Métodos de recomendação baseados em memória operam diretamente sobre a base de dados de avaliações de itens pelos usuários para geração de recomendações. Além disso, as recomendações estarão sempre atualizadas devido ao uso das mais recentes avaliações recebidas dos usuários (BOBADILLA et al., 2013).

Em geral, os sistemas produzem recomendações com base no conceito de vizinho mais próximos, onde o objetivo é encontrar semelhanças entre usuários ou entre itens com suporte nas diversas avaliações adquiridas pela base de dados (MUSTAFA et al., 2017). Por exemplo, se um usuário tem preferência em certos filmes de ficção científica e existe um outro que também tem algum gosto pelo gênero, ambos poderão ser classificados como vizinhos próximos. Em casos como esse, o grau de semelhança é obtido a partir de cálculos de similaridade.

3.2.1.1 Medidas de Similaridade

A similaridade entre usuários, itens, etc., podem ser obtidas a partir da matriz de avaliações dos usuários em relação aos itens. Os diversos algoritmos operam sobre as linhas ou colunas da tabela para encontrar um valor numérico que caracterize o grau de afinidade entre os objetos da comparação (AGGARWAL, 2016). Além disso, uma abordagem geométrica pode ser utilizada para aprimorar a observação do comportamento desses algoritmos (JONES; FURNAS, 1987).

O grau de semelhança entre dois usuários pode ser mensurado a partir de sua correlação, na qual estima a relação linear entre ambos. Dentre os diversos métodos, a correlação de *Pearson* avalia vetores de mesma dimensão (RICCI et al., 2010). Considerando, um conjunto de produtos $P = \{p_1, p_2, \dots, p_n\}$, um conjunto de usuários $U =$

$\{u_1, u_2, \dots, u_m\}$ e uma matriz de avaliações $R = \{r_{1,1}, r_{1,2}, \dots, r_{n,m}\}$ desses produtos em função dos usuários, com dimensão $n \times m$, tem-se a Equação 3.1 que descreve a correlação de Pearson entre dois usuários a e b .

$$sim(a, b) = \frac{\sum_{p \in P} (r_{a,p} - \bar{r}_a)(r_{b,p} - \bar{r}_b)}{\sqrt{\sum_{p \in P} (r_{a,p} - \bar{r}_a)^2} \sqrt{\sum_{p \in P} (r_{b,p} - \bar{r}_b)^2}} \quad (3.1)$$

Observa-se, inicialmente, a subtração de cada posição pelo valor médio das avaliações, o que reduz o efeito negativo, no cálculo, das notas de um determinado usuários que, em sua maioria, são ou altas, ou baixas. Além disso, tem-se um produto interno como numerador e a multiplicação dos comprimentos dos vetores de avaliação de cada usuário como denominador. Como possíveis resultados, a correção de Pearson gera valores entre -1 a 1 , onde o primeiro indica correlação negativa perfeita, ou seja, usuários com preferências opostas, e o segundo demonstra correlação positiva perfeita, implicando em gostos equivalentes entre os usuários (JANNACH et al., 2010).

Como exemplo, considerando a Tabela 3.1, deseja-se encontrar a similaridade entre os usuários Will e Elizabeth a partir de suas respectivas avaliações para os seis (6) itens e a correlação de Pearson. Fazendo uso da Equação 3.1, tem-se o seguinte cálculo:

$$\begin{aligned} sim(W, E) &= \frac{(3-3)(5-3,5) + (5-3)(3-3,5) + \dots}{\sqrt{(3-3)^2 + (5-3)^2 + \dots} \sqrt{(5-3,5)^2 + (3-3,5)^2 + \dots}} \\ sim(W, E) &= 0,21 \end{aligned}$$

Os usuários Will e Elizabeth têm portanto uma similaridade medida pela correlação de Pearson de $0,21$ indicando que ambos têm alguma semelhança entre suas preferências.

Em relação a similaridade de itens, o método do *cosseno* é considerado o padrão. Como base para o seu cálculo, se faz uso das avaliações dadas por todos os usuários a cada item, ou seja, as colunas da matriz de avaliação são utilizadas. No entanto, o método do cosseno não leva em conta o perfil de cada usuário ao considerar apenas a avaliação dada ao item em questão (JANNACH et al., 2010).

A Equação 3.2 define o cálculo de similaridade pelo método do cosseno onde, calcula-se o produto interno entre os vetores de avaliações dos itens, como numerador e a multiplicação dos comprimentos de cada

um como denominador.

$$sim(a, b) = \frac{\sum_{u \in U} (r_{u,a})(r_{u,b})}{\sqrt{\sum_{u \in U} (r_{u,a})^2} \sqrt{\sum_{u \in U} (r_{u,b})^2}} \quad (3.2)$$

Em outras palavras, para cada usuário u pertencente ao conjunto de usuário U , é calculada a multiplicação das suas avaliações para cada item e somada aos demais resultados da operação e, por fim, calcula-se o módulo de cada vetor. Um outra interpretação para o cálculo é considerar como sendo o produto interno entre os vetores de avaliação normalizados (JONES; FURNAS, 1987). Assim, com a divisão pelo comprimento, os possíveis resultados permanecem entre 0 e 1 (JANNACH et al., 2010), sendo que geometricamente, esses resultados podem ser avaliados como ângulos. As avaliações de um item podem ser consideradas componentes de um vetor que representa o objeto. Inserindo, então, os vetores num plano será formado um ângulo θ no qual, no contexto das avaliações de itens é obtido partir do arco cosseno do resultado da similaridade. Quanto mais próximo, esse ângulo estiver de zero grau (0°), maior será a semelhança entre os itens.

Como exemplo, pretende-se encontrar o grau de similaridade entre Item 2 e Item 5 da Tabela 3.1. Para tanto, considera-se as respectivas colunas de avaliações que usuários forneceram à cada um e a Equação 3.2. Por fim, tem-se o seguinte cálculo:

$$\begin{aligned} sim(2, 5) &= \frac{(4 \cdot 5) + (5 \cdot 1) + (3 \cdot 2) + (5 \cdot 4)}{\sqrt{4^2 + 5^2 + 3^2 + 5^2} \sqrt{5^2 + 1^2 + 2^2 + 4^2}} \\ sim(2, 5) &= 0,87 \end{aligned}$$

Os itens 2 e 5, portanto tem alta similaridade. Além disso, ao considerar a visão geométrica, têm-se um ângulo de $29,5^\circ$ formado entre os itens.

Como dito anteriormente, o método do cosseno não leva em conta o perfil de avaliações do usuário no cálculo da similaridade entre itens, no entanto, um método semelhante chamado *cosseno ajustado*, corrige essa imperfeição. Primeiramente, define-se o cálculo pela Equação 3.3.

$$sim(a, b) = \frac{\sum_{u \in U} (r_{u,a} - \bar{r}_u)(r_{u,b} - \bar{r}_u)}{\sqrt{\sum_{u \in U} (r_{u,a} - \bar{r}_u)^2} \sqrt{\sum_{u \in U} (r_{u,b} - \bar{r}_u)^2}} \quad (3.3)$$

Observa-se, então, que o ajuste se refere à subtração da média

das avaliações dadas pelo usuário u a todos os itens. Assim, o efeito negativo causado pela média alta ou baixa de avaliações do usuário é reduzido, deslocando as avaliações para a média do usuário ao invés da média do item. Além disso, o intervalo de valores possíveis com o método do cosseno ajustado, diferentemente do cosseno, é de -1 a 1 (JANNACH et al., 2010; RICCI et al., 2010). Por outro lado, nota-se a semelhança do método do cosseno ajustado em relação à correlação de Pearson, descrita na Equação 3.1. No entanto, apesar de semelhantes, os contextos aos quais aplica-se cada método é diferente. A correlação de Pearson é utilizada para o cálculo de similaridade entre usuários, já o cosseno ajustado destina-se a encontrar a semelhança entre itens, apesar de ambas fazerem uso da média de avaliações de cada usuário.

3.2.1.2 k Vizinhos Mais Próximos (kNN)

O kNN é um dos principais algoritmos para geração de recomendação e predições de avaliações (BOBADILLA et al., 2013), além de ter o objetivo geral de operar como classificador. Assim, dado um ponto em um espaço, o kNN encontrará os k pontos mais próximos com base em um conjunto de outros pontos pré-classificados e revelará à qual classe pertence.


Como exemplo, a Figura 3.1 traz dois conjuntos de pontos, azuis mais abaixo na imagem e vermelhos acima. Em meio a esses pontos à um outro, rosa, ao qual deseja-se saber à qual grupo pertence (independentemente de sua cor).

A partir de cálculos de similaridade o algoritmo encontrará os k pontos mais próximos, onde tal valor varia de acordo o contexto da aplicação. Duda, Hart e Stork (2000) sugerem um k igual a raiz quadrada do total de pontos n , ou seja, k é igual \sqrt{n} , no âmbito geral de classificadores, já no contexto de sistemas de recomendação, onde há bases com milhares de usuários, Jannach et al. (2010) afirma que k entre 20 a 50 é uma boa estimativa.

Em um aspecto gráfico, k pode ser interpretado como o número de pontos aos quais podem ser inseridos dentro de um círculo centrado no ponto que será classificado, como pode ser visualizado na Figura 3.2.

O algoritmo de k vizinhos mais próximos opera em três etapas, sendo a primeira, a determinação dos vizinhos mais próximos do usuário x conforme cálculos de similaridade. A seguir, previsões são computadas sobre as avaliações que x daria a itens, aos quais, ainda

Figura 3.1 – Exemplo de grupos para classificação com o kNN



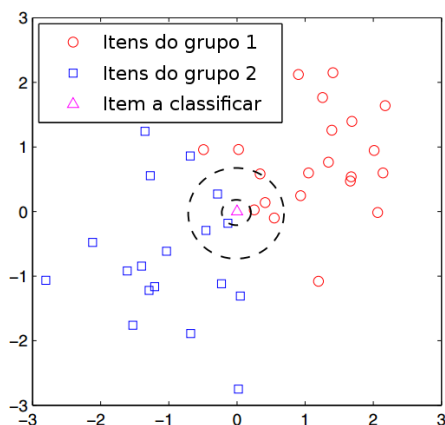
Fonte: Adaptado de Ricci et al. (2010)

não conhece, a partir de funções de agregação como, por exemplo, média e soma ponderada de notas de outros usuários ao item. Por fim, com base nas avaliações obtidas, os m itens com melhores notas são recomendados ao usuário (BOBADILLA et al., 2013).

O kNN pode ser aplicado nas duas categorias de filtragem colaborativa baseada em memória. A primeira delas é *baseada em usuário*, onde as sugestões são fundamentadas em outros utilizadores com preferências semelhantes. Assim, os itens recomendados não foram comprados pelo usuário ou este não os conhece, no entanto os mais semelhantes o fizeram (RICCI et al., 2010). Contudo, a abordagem tem um custo elevado para processamento da matriz de avaliações e geração de recomendações, onde, a cada recomendação produzida, todos os cálculos são re-executados, ou seja, opera em modo *online*.

A segunda abordagem é *baseada em item*, onde um item i é avaliado e indicado com base nas notas que o usuário u forneceu para itens similares aquele em questão. Itens são, então, similares se diversos usuários os avaliaram de maneira equivalente (RICCI et al., 2010). Ademais, o desempenho em termos de processamento, comparada à abordagem anterior, é superior, já que parte considerável do processamento pode ser feito *offline* (JANNACH et al., 2010; MIRANDA, 2010).

Figura 3.2 – Exemplo de classificação com o kNN



Fonte: Adaptado de Ricci et al. (2010)

3.2.2 Baseado em modelo

Sistemas de Recomendação baseados em modelo não fazem uso direto da matriz de avaliações para geração de recomendação, contudo ela é utilizada para o aprendizado de um modelo, ao qual fará as recomendações (ADOMAVICIUS; TUZHILIN, 2005). Primeiramente, os dados de avaliações são processados internamente, ou seja, *offline*, antes mesmo de recomendações serem calculadas. Assim, no momento, em que se recomendar itens, apenas o modelo será necessário (JANNACH et al., 2010). Entre as possíveis métodos para recomendação baseada em modelo tem a fatoração de matriz, métodos probabilísticos, redes neurais e baseados em regras de associação como se descreverá nas seções seguintes.

3.2.2.1 Fatoração de matriz

Os modelos de fatoração de matriz levam em conta usuários e itens para explicar as avaliações dadas a partir de vetores de fatores resultantes da inferência dos padrões de notas (KOREN; BELL; VOLINSKY, 2009). Tais fatores podem ser considerados características do item como, por exemplo, no contexto de livros, o autor, o gênero, no entanto, podem não ser interpretáveis, ou seja, não se consegue deter-

minar a qual característica se refere. A partir disso, recomendações serão feitas quando usuários e item forem semelhantes em relação a esses fatores (JANNACH et al., 2010). Por outro lado, o uso de avaliações explícitas pode não ser possível, devido à quantidade insuficiente de notas dadas por cada usuário. Apesar disso, o método permite o emprego de informações adicionais para obter as preferências de usuários. Avaliações implícitas obtidas a partir de seu comportamento além de históricos de compra, navegação e padrões de busca são utilizáveis nesse contexto (KOREN; BELL; VOLINSKY, 2009).

Entre as diversas técnicas existentes para encontrar os fatores latentes, há o método de Decomposição de Valor Singular (SVD). Neste modelo, cada item é ligado com um vetor q_i , no qual, os elementos indicam o quanto o item possui os fatores do vetor. Cada usuário é associado a um vetor p_u , que indica o grau de interesse do usuário nos itens que tem tais fatores altos ou baixos. Nesses casos, os valores que os fatores podem assumir estão entre -1 e 1 . A Equação 3.4 demonstra o cálculo para predição de avaliações do usuário u ao item i (RICCI et al., 2010).

$$\hat{r}_{ui} = \mu + b_u + b_i + q_i^T p_u \quad (3.4)$$

Ao efetuar o produto $q_i^T p_u$ exprime-se o interesse do usuário nas propriedades do item. Os demais termos da Equação 3.4 indicam a média global de avaliações de todos os itens (μ) e os desvios, em relação a μ , do usuário (b_u) e do item (b_i) (RICCI et al., 2010).

Por fim, o SVD é capaz de gerar boas recomendações, entretanto é computacionalmente caro e deve ser executado *offline*. Além disso, pode ser aplicado apenas em situações em que as informações de preferências não mudam com o tempo (BOBADILLA et al., 2013).

3.2.2.2 Métodos Probabilísticos

Os métodos probabilísticos procuram inferir a partir do uso de conceitos de estatística e probabilidade, as expectativas de eventos ocorrerem. No contexto de SR, significa mensurar a possibilidade de um usuário avaliar um determinado produto com a nota determinada. Para tanto, pode-se considerar a predição como um problema de classificação, onde se deseja colocar um objeto, entre diversas categorias, naquela que melhor se enquadra (JANNACH et al., 2010).

Entre os diversos métodos está o classificador de Bayes ao qual avalia a probabilidade de um evento ocorrer com base em outros even-

tos, ou seja, dados um conjunto de acontecimentos já decorridos no passado, qual a probabilidade de um determinado evento ocorrer no futuro. Assim, o teorema de Bayes, descrito pela Equação 3.5, pode ser usado para o cálculo da probabilidade para o evento (AGGARWAL, 2016).

$$P(A | B) = \frac{P(B | A) \cdot P(A)}{P(B)} \quad (3.5)$$

Considerando-se os eventos A e B, conforme Equação 3.5, a expectativa de o evento A ocorrer no futuro sabendo que B transcorreu é determinada a partir da probabilidade do evento A ocorrer por si só ($P(A)$), do evento B, individualmente, ($P(B)$) e a probabilidade do evento B ocorrer em função de A ($P(B | A)$).

No contexto de sistemas de recomendação o evento A, presente na Equação 3.5, é visto como a probabilidade do usuário u dar uma determinada nota v_s , dentre as possíveis notas, ao item i , tendo como base as avaliações já fornecidas por u . (AGGARWAL, 2016)

$$P(r_{ui} = v_s | r_u) = \frac{P(r_{ui} = v_s) \cdot P(r_u | r_{ui} = v_s)}{P(r_u)} \quad (3.6)$$

O método probabilístico com o Teorema de Bayes apresenta algumas vantagens, entre elas, a compensação de pontos de ruídos nos dados de treinamento, não ter *overfitting*, podendo assim aprender com modelos generalizados, além ser capaz de operar com um conjunto de dados pequeno (JANNACH et al., 2010).


3.2.2.3 Redes Neurais

Redes Neurais Artificiais (RNAs) tentam retratar de forma matemática, o comportamento do cérebro biológico, ao qual é formado por células chamadas neurônios e suas diversas interconexões, onde, a cada uma das ligações, é atribuído um peso. Desse modo, a aprendizagem consiste em alterar, a partir de treinamento, os valores de cada peso a fim de se ter um comportamento específico para a rede. Além disso, a entrada e saída da rede é composta por um conjunto de neurônios que são ligados a parte externa da rede. (RUSSELL; NORVIG, 2009).

A Figura 3.3 mostra uma RNA chamada Percéptron de Múltiplas Camadas (MLP), onde os neurônios são representados por quadrados e elipses, e as conexões entre eles, por setas indicando os pesos a elas

associados. A RNA mostrada tem duas entradas, representadas pelos neurônios um (1) e dois (2); dois neurônios, três (3) e quatro (4), na cada intermediária, também chamada oculta e, por fim, mais dois, cinco (5) e seis (6) na camada de saída.

Figura 3.3 – Rede Percéptron de Múltiplas Camadas



Fonte: Russell e Norvig (2009)

Redes neurais são capazes de aprender os padrões em dados de entrada e atuarem como classificadores. Entre as principais vantagens de RNA's de múltiplas camadas entre os demais classificadores é a capacidade de lidar com funções não-lineares, ou seja, a relação entre entradas e saídas é variável. (AGGARWAL, 2016).

No contexto de Sistemas de recomendação, redes neurais podem ser utilizadas para detectar padrões nas avaliações dadas pelos usuários aos diversos itens, e a partir disso, fazer previsões de notas à itens que o usuário ainda não avaliou (RICCI et al., 2010). Assim, considerando uma matriz de avaliações de usuários para itens, como na Tabela 3.1, a forma com a qual o usuário *Jack* avaliaria o *Item 4* pode ser determinada por RNA.

3.2.2.4 Baseado em regras de associação

Há uma relação entre sistemas baseados em regras e os sistemas de recomendação baseados em regras, onde o primeiro foi proposto para a descoberta das relações entre transações. Assim, busca-se, por exemplo, descobrir qual a relação de compra de produtos entre as diversas transações, ou seja, se a aquisição de um item pode implicar na compra de outro (AGGARWAL, 2016).

Recomendações são feitas para um usuário com base nas regras de associação que melhor se encaixam no seu histórico de transações. Por fim, a partir de informações de relação de compras de produtos é

possível aplicar promoções e mudança de layout de estabelecimentos (JANNACH et al., 2010).

3.3 BASEADA EM CONTEÚDO

Sistemas de Recomendação baseados em conteúdo, aos quais têm como origens as pesquisas de filtragem de informação e recuperação de informação (CAZELLA; NUNES; REATEGUI, 2010), tentam recomendar itens ao usuário de acordo com as características de itens que ele gostou e das características do item em específico (RICCI et al., 2010). A recomendação será feita a partir da correspondência do perfil do usuário com as características dos itens. Assim, para esse tipo de sistema necessita-se apenas dos dados referentes aos itens, ou seja, sua descrição, e às preferências de usuário, isto é, seu perfil, não carecendo de uma grande comunidade de usuários para fazer recomendações. (JANNACH et al., 2010).

3.3.1 Descrição do item

Um item pode ser descrito em termo de seus atributos ou de seu conteúdo. No contexto de SR baseado em conteúdo essa definição pode ser obtida a partir de duas formas, sendo elas a explícita e implícita (JANNACH et al., 2010). A forma explícita faz uso de características bens definidas dos itens. No caso de um livro, por exemplo, essas características são autor, gênero, preço, número de páginas entre outros. Em um sistema de recomendação essas informações devem ser inseridas manualmente para que possam ser utilizadas nos algoritmos. Por outro lado, a forma implícita faz uso de algoritmos que extraem informações dos itens. Além disso, essa abordagem é amplamente utilizada no contexto de recomendação de documentos textuais como, por exemplo, artigos científicos (GARCIA; FROZZA, 2013).

Entre as diversas abordagens de representação de itens textuais está o modelo vetor de espaço baseado em palavras-chave. Nesse caso, busca-se representar um item por um conjunto de palavras melhor o descrevem (JANNACH et al., 2010).

Um padrão seguido para SR baseada em conteúdo para documentos textuais é usar o conteúdo em si do item para gerar recomendação e não os meta-dados, ou seja, as informações sobre o item. Entre as abordagens que aplicam esse conceito está a TF-IDF, onde os itens

são representados como vetores de pesos, sendo cada posição correspondente a um termo com sua respectiva relevância, no contexto de documentos textuais. O TF-IDF é composto de um produto de dois pesos, o primeiro a Frequência do Termo (TF) e a Frequência Inversa do Documento (IDF), onde TF indica a frequência de cada termo no documento. No entanto, documentos maiores terão frequências maiores para as palavras e os menores o contrário, tornando injusta a medição por frequência absoluta. Por isso, é necessária uma normalização (JANNACH et al., 2010).

A Equação 3.7 apresenta o cálculo do TF, onde calcula-se a frequência normalizada de um termo i em um item j com base na frequência absoluta do termo no documento dividido pela número de ocorrências da palavra mais frequente entre no documento (JANNACH et al., 2010).

$$\text{TF}(i, j) = \frac{\text{freq}(i, j)}{\max \text{Outros}(i, j)} \quad (3.7)$$

Já o IDF tem por objetivo reduzir o impacto de palavras demasiadamente frequentes, ou seja, que são comuns em diversos documentos, como preposições e artigos. A Equação 3.8 demonstra o cálculo do IDF para o termo i de acordo com o número total de documentos recomendáveis N e $n(i)$, o número de documentos em que i aparece (JANNACH et al., 2010).

$$\text{IDF}(i) = \log \left(\frac{N}{n(i)} \right) \quad (3.8)$$

O cálculo de TF-IDF é, portanto, definido pela Equação 3.9

$$\text{TF-IDF}(i, j) = \text{TF}(i, j) \cdot \text{IDF}(i) \quad (3.9)$$

Por fim, técnicas são necessárias para eliminar termos irrelevantes do documento. A primeira se refere a retirada de palavras de parada, como artigos e preposições. Outra técnica, lematização, consiste em substituir palavras semelhantes por sua palavra original, como “ligado”, “ligou” e “liga” poderiam ser trocadas por “ligar”. Outra maneira é reduzir o tamanho do vetor que representa o item, para as n palavras que melhor o representam (JANNACH et al., 2010).

3.3.2 Perfil de usuário

O perfil do usuário consiste num conjunto de características em que demonstrou-se, no passado, interesse por parte do indivíduo. Além disso, tal perfil pode ser adquirido de duas maneiras: explícita ou implícitamente. Na abordagem explícita, o usuário é diretamente indagado sobre seus gostos e preferências através de um conjunto de questionamentos elaborados pelo sistema e, fundamentando-se nas respostas, o perfil é traçado (ADOMAVICIUS; TUZHILIN, 2005).

Na forma implícita, por outro lado, é utilizado o histórico do usuário para extrair suas preferências a partir de algoritmos de aprendizado de máquina ou *machine learning*. Segundo Mitchell (1997), aprendizado de máquina consiste em permitir que um computador aprenda a executar um conjunto de tarefas a partir de um conjunto de dados de experiências prévias. Entre as técnicas de aprendizado de máquina aplicadas a extração de perfil de usuário estão Árvores de Decisão, Redes Neurais, Feedback de Relevância além da computação evolucionária a partir algoritmos genéticos e, por fim, métodos probabilísticos (RICCI et al., 2010).

3.3.3 Recomendação

Recomendações são feitas, no contexto de vetores de espaço, a partir da combinação dos vetores que descrevem os itens com o vetor que descreve as preferências de usuário. Assim, os itens com maiores semelhanças com o perfil do usuário são recomendados (AGGARWAL, 2016).

3.4 BASEADA EM CONHECIMENTO

Quando se trata de recomendar, nem sempre se terá à disposição uma base de dados com o histórico de interações de usuários. Além disso, mesmo com a existência de tal base, os dados contidos podem não ser úteis quando trata-se de itens com longa duração como carros, casas, entre outros, onde a ocorrência de compras é muito baixa, em torno de anos (JANNACH et al., 2010). Assim, as abordagens descritas anteriormente, ou seja, baseada em filtragem colaborativa e baseada em conteúdo, não são aplicáveis já que não há uma base de dados confiável para extrair informações e traçar um perfil para cada usuário (RICCI

et al., 2010). Por outro lado, há ocasiões em que o usuário esteja disposto a adquirir um produto que possua um conjunto de características específicas.

Em meio às situações descritas, surge uma abordagem denominada recomendação baseada em conhecimento. Essa abordagem explora outros meios de informações, sendo elas informações sobre o usuário e sobre o item. Assim, pode ser descrita como uma forma de se obter um conjunto de itens para recomendação aos quais satisfazem um conjunto de restrições definidas pelo usuário, podendo ser características, recursos, etc. (JANNACH et al., 2010).

Segundo Ricci et al. (2010) e Aggarwal (2016), há dois tipos específicos sendo eles, baseado em restrições e baseado em casos, que diferem de acordo com o modo utilizado para obter itens para indicação.

3.4.1 Baseado em restrições

É mais rígido onde apenas itens com as características definidas pelas regras são escolhidos. Além disso, a tarefa de levantar um conjunto de itens que satisfaz as necessidades do consumidor é denotada como uma tarefa de recomendação (RICCI et al., 2010). Segundo Schreiber et al. (1999), tarefa define, em termos de pares de entrada e saída, um objetivo de raciocínio. Assim, a tarefa de recomendação busca a partir de um conjunto de requisitos elencar um conjunto de itens que os satisfaz.

A tarefa é executada sobre uma base de conhecimento, ao qual contém regras que relacionam os requisitos do usuário com as características dos itens. Assim, a base é formada por dois conjuntos de variáveis, V_C e V_{PROD} , e três conjuntos de restrições, C_R , C_F , C_{PROD} , C_C . O primeiro conjunto de variáveis, V_C , trata das propriedades do usuário, ou seja, a descrição possível dos requisitos de usuários como peso, tamanho etc. Já o outro conjunto de variáveis, V_{PROD} , descreve as propriedades de um dado item pode ter.

Por outro lado, em relação ao conjunto de restrições, o primeiro deles, C_R , restringe sistematicamente os possíveis valores das propriedades de usuários, como por exemplo, a propriedade “tamanho” deve ter o valor “pequeno”. O segundo conjunto, C_F , define condições de filtragem e define a relação entre o usuário e um produto. O terceiro conjunto, C_{PROD} define os possíveis valores que as propriedades que o item pode ter como, por exemplo, a propriedade “tamanho” para um item, pode assumir os valores “pequeno”, “médio”, “grande”. Por fim,

o último conjunto, C_C se refere às restrições que representam requisitos do usuário.

Com base nos conjuntos de restrições e de variáveis, uma solução para o problema de satisfação de restrições consiste em instanciações das variáveis de tal forma que as restrições especificadas são atendidas. Para tanto, faz-se uso de algoritmos de satisfação de restrições além de consultas conjuntivas de banco de dados. Após um conjunto de itens ser selecionado é feito um ranqueamento indicando os resultados mais relevantes (RICCI et al., 2010).

3.4.2 Baseado em caso

Essa abordagem confere uma tolerância maior ao não cumprimento das regras, já que recomenda itens semelhantes às restrições. Itens são recuperados usando medidas de similaridade que descrevem o quanto as propriedades do item se aproximam com alguns requisitos de usuário (AGGARWAL, 2016). Caso o usuário considerem inadequados os itens resgatados, este pode modificar os requisitos e uma nova recomendação é feita (LORENZI; RICCI, 2005). Assim, tem-se a distância de similaridade para comparação de requisitos e itens, onde um item p e requisitos r pertencentes a REQ são comparados através da Equação 3.10, onde w é a importância do requisito r e $\text{sim}(p, r)$ é a distância da característica em relação à expressa pelo usuário (JANNACH et al., 2010).

$$\text{sim}(p, REQ) = \frac{\sum_{r \in REQ} w_r \cdot \text{sim}(p, r)}{\sum_{r \in REQ} w_r} \quad (3.10)$$

Um sistema baseado em caso terá uma base de casos, na qual condiciona um conjunto de problemas e soluções prévias. Problemas novos são, então, solucionados a partir da adaptação das soluções de problemas similares anteriores (BRIDGE et al., 2005).

3.5 ABORDAGEM HÍBRIDA

As abordagens descritas até o presente momento se destacam em determinadas situações, mas deixam a desejar em outras. Por exemplo, a Filtragem Colaborativa, como será descrito na Seção 3.7, apresenta dificuldades em gerar recomendações adequadas para um novo usuário e para um novo item (RICCI et al., 2010). Deste modo, como

forma de contornar as limitações das abordagens, surgem os sistemas de recomendação híbridos, onde se aplica em um mesmo SR, diversas abordagens, para gerar recomendações, permitindo que os pontos fortes de cada uma sejam utilizados enquanto os pontos fracos atenuados. Para tanto, os SR's fazem uso de múltiplos dados de entrada, geralmente utilizados por cada abordagem, sendo eles, avaliações de itens, perfis de usuários, modelos de conhecimento, características dos itens, entre outros. As abordagens chamadas “puras” utilizam algumas dessas entradas, enquanto a abordagem híbrida pode empregar múltiplas fontes de informação (JANNACH et al., 2010).

O processo de hibridização de um sistema de recomendação, ou seja, a mesclagem de diversas abordagens, pode seguir algum método específico que indique como e quando os itens de recomendação de cada abordagem serão utilizados. Jannach et al. (2010) expõe três métodos para tornar SRs híbridos: monolítico, paralelo e sequencial, cada um com suas respectivas subdivisões.

O método monolítico apresenta um único componente que integra múltiplas abordagens por pré-processamento e combinação de múltiplas fontes de dados (AGGARWAL, 2016), ou seja, apenas um componente abriga todas as abordagens aplicadas no sistema, onde troca-se o comportamento explorando os diferentes tipos de dados de entrada. Sistemas híbridos com design monolítico podem ser sub-categorizados em dois outros designs sendo eles por combinação de características e aumento de características (JANNACH et al., 2010).

O modo paralelo faz uso de mais componentes, ao contrário do monolítico, cada qual contendo um SR e que, assim, são utilizados de forma simultânea e independente (AGGARWAL, 2016). As respectivas saídas são combinadas a partir de mecanismos de agregação, sendo o mesclado, ponderado e chaveado (JANNACH et al., 2010).

A forma sequencial aplica as diversas abordagens sequencialmente (JANNACH et al., 2010), ou seja, a saída da abordagem atual é aplicada como entrada na seguinte e, assim, sucessivamente até a última abordagem gerar o conjunto de itens para recomendação ao usuário (BURKE, 2002). Esse tipo de design pode ser dividido, além disso, em duas categorias: cascata e meta-nível (JANNACH et al., 2010).

3.6 OUTRAS ABORDAGENS

Além das abordagens clássicas para sistemas de recomendação, há outras relevantes que merecem ser citadas. Nas próximas subseções

algumas delas são brevemente apresentadas.

3.6.1 Baseada em Contexto

Muitos SRs não levam em conta as circunstâncias e outras informações de contexto que levam ao usuário a decidir pela aquisição de um item como, por exemplo, a quem se destina, quando e onde será feito usufruto, onde ocorre a compra entre outras informações relevantes (RICCI et al., 2010; PANNIELLO; GORGOGLIONE, 2012).

Sistemas baseados em contexto pode ser divididos em duas classes: por consulta dirigida ao contexto e por estimativa e elicitação de preferência contextual. O primeiro é utilizado por aplicações onde se utiliza das informações de contexto para buscas em repositórios de recursos aos quais sugerem serviços correspondentes. Já o segundo se refere à inclusão de informação de contexto em SRs a fim de aprimorar as recomendações. Para tanto, três paradigmas são apresentados: pré-filtragem contextual ao qual filtra dados irrelevantes antes de computar recomendações, pós-filtragem contextual, aplicada após um conjunto de itens ser gerado e modelagem contextual que é aplicada na geração de recomendações. (PANNIELLO; GORGOGLIONE, 2012).

3.6.2 Baseada em Utilidade

Usuários quando interagem com o conjunto de itens recomendados por um SR tendem a dar mais atenção aos posicionados no topo da lista. Assim, é essencial que a lista de recomendações seja ordenada de acordo com a relevância do item ao usuário. Nesse sentido, a abordagem baseada em utilidade busca, como a própria nomenclatura exprime, ranquear os itens de acordo com a sua utilidade. Para tanto, cada objeto é avaliado a partir de um conjunto de dimensões ou características como qualidade, preço, entre outras. A utilidade é, então, calculada a partir da soma das contribuições do item para cada dimensão bem como pelo interesse do usuário na característica (JANNACH et al., 2010). Por fim, sistemas baseados em utilidade tem sido classificados como uma subdivisão de sistemas baseados em conhecimento (AGGARWAL, 2016).

3.6.3 SRs Sociais

Os sistemas de recomendação passaram a incorporar dados de interações sociais como posts, tags, lista de amigos etc., com o desenvolvimento da Web 2.0. A partir dessas informações pode-se aprimorar a qualidade das recomendações fornecidas pelas abordagens como a baseada em filtragem colaborativa. Além disso, essas informações podem ser utilizadas para criar novas recomendações bem como elucidar as relações entre os processos colaborativos e os dados de interações sociais (BOBADILLA et al., 2013). A partir disso, é possível recomendar conexões entre usuários, páginas web entre outros (AGGARWAL, 2016).

3.6.4 SRs Demográficos

Sistemas de Recomendação Demográficos utilizam dados relativos aos usuários como idade, sexo, profissão, além de hábitos como o de assistir a certos canais de televisão, prática de esportes, entre outros (KRULWICH, 1997). Com base nesses dados, esses sistemas fazem uso de classificadores para dividir os usuários em grupos que compartilham das mesmas características (AGGARWAL, 2016), partindo da premissa de que pessoas em um mesmo grupo tendem a gostar dos mesmos tipos de itens (PAZZANI, 1999).

SRs Demográficos não são capazes de recomendações melhores que abordagens tradicionais, como filtragem colaborativa ou baseada em conteúdo, entretanto, quando incorporados a essas e outras abordagens, a qualidade das recomendações é melhorada significativamente (AGGARWAL, 2016).

3.7 DESAFIOS

Os sistemas de recomendação apresentam algumas limitações e obstáculos que dificultam que as recomendações sejam calculadas e realizadas.

Quando o sistema recebe novos usuários para recomendação não há informações suficientes sobre suas preferências que possibilite a geração de recomendações para ele (BOBADILLA et al., 2013). Por outro lado, em relação aos itens, não existe nenhuma interação com usuários que permita ser recomendado a alguém. Os sistemas de recomendação “puros”, ou seja baseados em filtragem colaborativa, baseados em con-

teúdo entre outros, não conseguem lidar com esses problemas, também chamados de *cold start* ou partida fria, no entanto, sistemas híbridos o fazem (MIRANDA, 2010).

Além do problema em recomendar novos itens, há o efeito gerado pela adição deste item, ou seja, o conjunto de recomendação prévio não leva em conta esse novo item e, portanto, pode não ser preciso. Assim, é necessário que o sistema ajuste as bases de recomendação para que o novo item seja recomendado. No entanto, tais bases contêm entre centenas à milhares de itens e usuários e, por isso, efetuar a atualização de uma base de grande porte pode ser custoso e inviável para cada novo item acrescentado. Esse problema se refere à escalabilidade de sistemas de recomendação (Lü et al., 2012).

Outro desafio se refere a esparsidade, ou seja, a proporção dos itens avaliados por usuários em relação ao número total de itens é consideravelmente pequena e mal distribuída. Além disso, a intersecção do conjunto de itens avaliados por pares de usuários tende a ser modesta. Isso acontece em função da baixa taxa de avaliação de itens, seja explícita ou implicitamente (Lü et al., 2012; SHARMA; GOPALANI; MEENA, 2017).

A diversidade das recomendações é outra questão relevante, à qual se refere à capacidade dos SRs sugerir recomendações variadas, seja em relação aos usuários, ou seja, diferentes resultados para diferentes usuários, seja em relação aos itens, através da sugestão de itens distintos para um mesmo usuário (Lü et al., 2012). Nesse sentido, um usuário que demonstra preferência por livros de ficção científica, por exemplo, teria como sugestão não apenas obras do gênero.

3.8 APLICAÇÕES

A aplicabilidade de Sistemas de Recomendação é ampla (citar), indo desde sites de comércio eletrônicos até a área da saúde. Os primeiros sistemas, como descrito no início do capítulo, objetivavam reduzir a carga de informações ao usuário categorizando e recomendando os itens (GOLDBERG et al., 1992; RESNICK et al., 1994). No entanto, com o expansão e do da Internet novos aplicações de sistemas de recomendação surgiram, entre elas, no comércio eletrônico, em plataformas de *streaming*, turismo e, recentemente, na Internet das Coisas.

Na área de comércio eletrônico, as avaliações são costumeiramente utilizadas, além do histórico de interações com os produtos, seja na forma de visualização ou compra. Com base nesses dados de usuá-

rios, esses sistemas geram recomendações (LU et al., 2015). Empresas como Amazon¹, Saraiva² e Walmart³ recomendam produtos para seus usuários. Tratando da Amazon, por exemplo, recomendações são feitas por diversos meios considerando diversos aspectos, ou seja, a partir da página web ou por e-mail são sugere-se produtos com base no que visualizado e/ou comprado bem como, produtos mais vendidos, aqueles que costumam ser comprados em conjunto com determinado produtos entre outras situações (KRAWIEC, 2016), através de filtragem colaborativa baseada em item (SMITH; LINDEN, 2017).

Sistemas de Recomendação também são utilizados em plataformas de *streaming*, como Netflix⁴ e Spotify⁵ onde filmes, séries ou músicas são recomendados. A Netflix, por exemplo, lançou, em 2006, uma competição chamada *Netflix Prize* ao qual oferecia um milhão de dólares a quem, a partir de um conjunto de dados fornecido, aprimorasse o sistema de recomendação baseado em fatoração de matriz em 10% sobre a Raiz Quadrada do Erro Médio Quadrático (RMSE). Como resultado, as pesquisas sobre a técnica eclodiram, resultando em um vencedor em 2009 (JANNACH et al., 2016).

O novo paradigma da Internet das Coisas comportará aplicações que comportarão sistemas de recomendação. Para tanto, dados locais e pessoais serão coletados implicitamente através dos vários sensores e dispositivos da IoT. A partir disso, tem-se a representação do contexto de usuários e recomendações proativas poderão ser entregues no momento mais apropriado e sem a requisição direta da sugestão (SALMAN et al., 2015). As possíveis recomendações poderão abranger, além de itens, serviços (MASHAL; CHUNG; ALSARYRAH, 2015).

Sistemas de Recomendação são aplicáveis não apenas nas áreas apresentadas anteriormente, mas também na saúde (FERRETTO; CERVI; MARCHI, 2017), educação (WAI, 2016; MONTUSCHI et al., 2015), turismo (SMIRNOV et al., 2013; FRIKHA et al., 2016), engenharia de software (HAMZA; WALKER, 2015), entre outros.

¹<https://www.amazon.com.br>

²<https://www.saraiva.com.br>

³<https://www.walmart.com.br>

⁴<https://www.netflix.com>

⁵<https://www.spotify.com>

4 SISTEMA PROPOSTO

4.1 INTRODUÇÃO

4.2 ARQUITETURA

Essa seção descreve a arquitetura do sistema através de duas modelagens: lógica e física. A primeira apresenta os componentes abstraindo as tecnologias envolvidas na sua composição. Já o modelo complementa a visão lógica a partir do detalhamento da implementação dos componentes bem como as tecnologias empregadas em suas respectivas implementações.

4.2.1 Modelo lógico

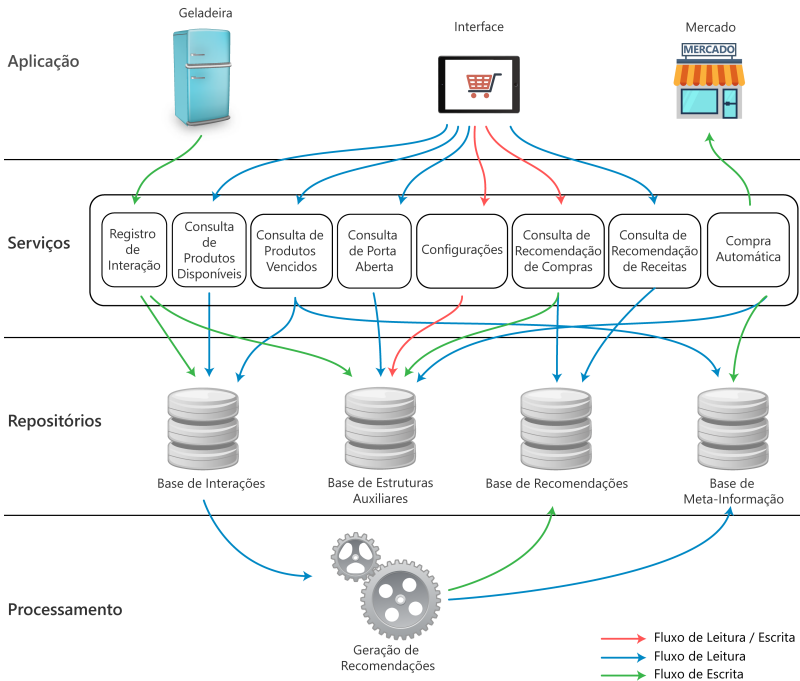
O modelo lógico do sistema proposto neste trabalho é apresentado na Figura 4.1. Pode-se observar, portanto, quatro camadas: aplicação, serviços, repositórios e processamento. A primeira delas, de aplicação, envolve todos os agentes externos ao servidor principal, sendo eles, geladeira, interface de usuário e o mercado. Já as demais, de serviços, repositórios e processamento se encontram dentro do servidor sendo estas separadas por módulos.

4.2.1.1 Camada de Aplicação

A camada de aplicação, como já dito, envolve os agentes externos. O primeiro deles é a geladeira à qual é responsável por monitorar os produtos nela contidos. Deste modo, a cada interação do usuário com a geladeira, esta fará uma varredura para verificar o conjunto de produtos existentes. Em seguida, enviará tais informações para o servidor através do serviço de registro de interação. Além disso, a geladeira também é responsável por verificar a condição de fechamento porta e, caso aberta, a geladeira fará um registro através do serviço de estruturas auxiliares para que o sistema seja capaz de emitir um aviso ao usuário.

O componente seguinte é a interface de usuário que é incorporada à porta da geladeira e que responsabiliza-se por permitir ao usuário a

Figura 4.1 – Modelo lógico



Fonte: Autores

interação com o eletrodoméstico. A partir disso, tem-se como funcionalidades deste componente, a listagem de produtos contidos, produtos com prazos de validade próximos, avisos de porta aberta, configurações e, por fim, recomendações de possíveis compras de produtos e receitas.

O último componente é o mercado. Através dele, será possível efetivar as compras a partir da lista de produtos selecionada pelo usuário dentre os recomendados. Além disso, é possível fazer consultas de promoções de itens que eventualmente serão disponibilizadas pelo mercado. Por fim, esse componente pode ser interpretado como outro sistema que apresenta seus respectivos serviços e repositórios.

4.2.1.2 Camada de Serviços

A camada de serviços disponibiliza um conjunto de funcionalidades aos componentes da camada de aplicação se comportando como

intermediadora entre aplicação com o sistema principal. Assim, há um conjunto de serviços específicos disponibilizados conforme a Figura 4.1 e que serão descritos nos parágrafos seguintes.

O serviço de registro de interação receberá informações dos itens contidos da geladeira além do alerta de porta aberta. Em seguida, registra-se tais informações na base de interações e de estruturas auxiliares, respectivamente.

Já o serviço de consulta de produtos disponíveis será requisitado pelo usuário através da interface. Então, será feita uma busca na base de interações pelo último registro feito ao qual conterá os produtos existentes.

O serviço de consulta de produtos vencidos é realizada periodicamente pela interface. Desse modo, é feita uma busca pelo itens disponíveis na geladeira e o tempo que estão presentes através da base de interações. Logo após, é feita uma consulta na base de meta-informação para determinar o tempo estimado de validade de cada produto encontrado. A partir da comparação entre tempo de acondicionamento e prazo de expiração, sabe-se se o produto está vencido ou não. A estimativa é feita pois o prazo de validade transcrito em produtos não condiz após a abertura do produto. Assim, uma estimativa de tempo menor é necessária.

O serviço de consulta de porta aberta é requisitado pela interface de usuário periodicamente de forma automática. Como efeito da requisição, faz-se uma consulta à base de estruturas auxiliares a fim verificar a existência de um registro recente de porta aberta. O resultado é então encaminhado para a interface que alertará o usuário, caso necessário.

O serviço de configurações permite que o usuário personalize algumas características do funcionamento da geladeira. A primeira delas se refere ao mercado no qual as compras são realizadas.

O serviço de consulta de recomendação de compras é requisitado pela aplicação periodicamente. Assim, quando é feita uma requisição, o serviço faz uma consulta à base de recomendações em busca de possíveis sugestões. O conjunto existente é então retornado para a interface que, por sua vez, indaga ao usuário se deseja realizar a compra e quais produtos deseja adquirir, dentre os apresentados. A lista é retornada ao serviço que, então, faz o registro na base de estruturas auxiliares.

O serviço de recomendação de receitas recebe uma requisição do usuário e faz uma consulta à base de recomendações. Caso existam receitas para recomendar, essas serão listadas ao usuário na interface e será possível então a escolha de qual receita deseja-se visualizar.

O serviço de compra automática é executado automaticamente quando há uma lista de compras pendente. Assim, a partir da verificação de tal pendência na base de estruturas auxiliares, a compra é requisitada ao agente mercado e como retorno, informações a cerca das características dos produtos serão retornadas e gravadas na base de meta-informação para uso posterior pelo mecanismo gerador de recomendação.

4.2.1.3 Camada de Repositórios

O conjunto de repositórios desta camada atuam na persistência de informações geradas pelos diversos componentes e pelo gerador de recomendação. Nessa modelagem, dividiu-se em quatro bases: de interações, de estruturas auxiliares, de recomendações e de meta-informação. A primeira base é responsável, como descrito anteriormente, pelo registro de produtos acondicionados na geladeira. A partir disso, as consultas realizadas nessa base recuperarão os itens constantes após cada interação do usuário.

A base de estruturas auxiliares contém informações que são utilizadas por mais de um serviço. Tais informações são alertas de porta aberta, configurações e as listas de compras determinadas pelo usuário.

Já a base de recomendações armazena todas as sugestões de receitas e de compras construídas pelo gerador e que serão apresentadas ao usuário.

A última base, de meta-informação contém informações referentes ao conteúdo dos produtos adquiridos e que são utilizadas pelo gerador de recomendações e pelo serviço de verificação de produtos vencidos. Tais informações incluem características do produto bem como tempo estimado de validade.

4.2.1.4 Camada de Processamento

A camada de processamento contém o módulo de geração de recomendações. Tal componente faz uso das informações armazenadas na base de interação e das características de cada item mantidas na base de meta-informações.

As recomendações de receitas fazem uso da base de interações para ter conhecimento dos produtos contidos atualmente e de meta-informações para resgatar as receitas e seus respectivos ingredientes.

A partir disso, é feita uma comparação entre as bases. Caso alguma receita requeira itens que já estão presentes, essa será recomendada ao usuário. Do contrário, caso apenas alguns poucos itens estejam em falta, será sugerida, ao usuário, além da receita, a compra de tais produtos faltantes.

Compras são sugeridas com base na quantidade existente de um certo produto. Assim, quando tal valor cai abaixo da quantidade mínima, determinada pelo usuário, é feita a recomendação de compra do mesmo item. No entanto, o mercado pode não ter à disposição o produto específico, mas pode conter similares. Nesse caso, o sistema faz uma busca por itens similares e pede a aprovação do usuário para a compra do item semelhante, ao invés do original. Além disso, sugere-se novos itens com base em promoções que por ventura o mercado venha a disponibilizar e que o usuário tenha apresentado interesse em tais produtos.

4.2.2 Modelo físico

4.2.3 Exemplo de fluxo de execução

5 AVALIAÇÃO DO SISTEMA PROPOSTO

6 CONSIDERAÇÕES FINAIS

6.1 CONCLUSÕES

6.2 TRABALHOS FUTUROS

REFERÊNCIAS

ADOMAVICIUS, G.; TUZHILIN, A. Toward the next generation of recommender systems: a survey of the state-of-the-art and possible extensions. **IEEE Transactions on Knowledge and Data Engineering**, Institute of Electrical and Electronics Engineers (IEEE), v. 17, n. 6, p. 734–749, jun 2005. ISSN 1041-4347.

AGGARWAL, C. C. **Recommender Systems**. [S.l.]: Springer International Publishing, 2016. ISBN 978-3-319-29657-9.

AGHAEI, S.; NEMATBAKHS, M. A.; FARSANI, H. K. Evolution of the world wide web: From web 1.0 to web 4.0. **International Journal of Web & Semantic Technology**, Academy & Industry Research Collaboration Center (AIRCC), v. 3, n. 1, p. 1, 2012.

AL-FUQAHA, A. et al. Internet of things: A survey on enabling technologies, protocols, and applications. **IEEE Communications Surveys & Tutorials**, Institute of Electrical and Electronics Engineers (IEEE), v. 17, n. 4, p. 2347–2376, Fourthquarter 2015. ISSN 1553-877X.

AMAZON. **Amazon Echo - Black**. 2017. Disponível em: <<https://www.amazon.com/Amazon-Echo-Bluetooth-Speaker-with-WiFi-Alexa/dp/B00X4WHP5E>>.

APPLE. **Getting Started with iBeacon**: Version 1.0. jun 2014. 1–11 p. Disponível em: <<https://developer.apple.com/ibeacon/Getting-Started-with-iBeacon.pdf>>.

ASANO, S.; YASHIRO, T.; SAKAMURA, K. Device Collaboration Framework in IoT-Aggregator for Realizing Smart Environment. In: **2016 TRON Symposium (TRONSHOW)**. Tokyo: Institute of Electrical and Electronics Engineers (IEEE), 2016. p. 1–9. ISBN 9784893623249.

BLUETOOTH SIG. **Bluetooth 5**. 2017. Disponível em: <<https://www.bluetooth.com/specifications/bluetooth-core-specification/bluetooth5>>.

BLUETOOTH SIG. **Bluetooth Core Specification**. 2017. Disponível em: <<https://www.bluetooth.com/specifications->

/bluetooth-core-specification>. Acesso em: 09 de Abril de 2017.

BLUETOOTH SIG. **How It Works**: Bluetooth is the foundation for transformative wireless connectivity. jan 2017. 58–71 p. Disponível em: <<https://www.bluetooth.com/what-is-bluetooth-technology/how-it-works>>.

BOBADILLA, J. et al. Recommender systems survey. **Knowledge-Based Systems**, Elsevier BV, Amsterdam, The Netherlands, The Netherlands, v. 46, p. 109–132, jul 2013. ISSN 0950-7051. Disponível em: <<http://dx.doi.org/10.1016/j.knosys.2013.03.012>>.

BRIDGE, D. et al. Case-based recommender systems. **The Knowledge Engineering Review**, Cambridge University Press, v. 20, n. 3, p. 315–320, 2005.

BRIN, S.; PAGE, L. The anatomy of a large-scale hypertextual web search engine. **Comput. Netw. ISDN Syst.**, Elsevier Science Publishers B. V., Amsterdam, The Netherlands, The Netherlands, v. 30, n. 1-7, p. 107–117, abr. 1998. ISSN 0169-7552. Disponível em: <[http://dx.doi.org/10.1016/S0169-7552\(98\)00110-X](http://dx.doi.org/10.1016/S0169-7552(98)00110-X)>.

BURKE, R. Hybrid recommender systems: Survey and experiments. **User Modeling and User-Adapted Interaction**, Kluwer Academic Publishers, Hingham, MA, USA, v. 12, n. 4, p. 331–370, nov. 2002. ISSN 0924-1868. Disponível em: <<http://dx.doi.org/10.1023/A:1021240730564>>.

CARDOSO, I. G. et al. Vulcanus 2.0: A Recommender System for Accessibility. **CLEI Electronic Journal**, scielouy, v. 19, p. 6 – 6, 04 2016. ISSN 0717-5000. Disponível em: <http://www.scielo.edu.uy/scielo.php?script=sci_arttextpid=S0717-50002016000100006nrm=iso>.

CAZELLA, S. C.; NUNES, M.; REATEGUI, E. A ciência da opinião: Estado da arte em sistemas de recomendação. **André Ponce de Leon F. de Carvalho; Tomasz Kowaltowski.(Org.). Jornada de Atualização de Informática-JAI**, p. 161–216, 2010.

CECILIA, A. A.; SUDARSANAN, K. A survey on smart grid. In: **1st International Conference on Emerging Trends in Engineering, Technology and Science, ICETETS 2016 -**

Proceedings. [S.l.: s.n.], 2016. p. 1–7. ISBN 9781467367257. ISSN 1553-877X.

CERVO, A.; BERVIAN, P.; SILVA, R. da. **Metodologia científica.** 6ª. ed. [S.l.]: Pearson Prentice Hall, 2007. ISBN 9788576050476.

CHIANG, M.; ZHANG, T. Fog and IoT: An Overview of Research Opportunities. **IEEE Internet of Things Journal**, v. 4662, n. c, p. 1–1, 2016. ISSN 2327-4662. Disponível em: <<http://ieeexplore.ieee.org/lpdocs/epic03/wrapper.htm?arnumber=7498684>>.

COCCHIA, A. Smart and digital city: A systematic literature review. In: _____. **Smart City: How to Create Public and Economic Value with High Technology in Urban Space.** Cham: Springer International Publishing, 2014. p. 13–43. ISBN 978-3-319-06160-3. Disponível em: <http://dx.doi.org/10.1007/978-3-319-06160-3_2>.

DUDA, R. O.; HART, P. E.; STORK, D. G. **Pattern Classification.** [S.l.]: Wiley John + Sons, 2000. ISBN 0471056693.

FALUDI, R. **Building Wireless Sensor Networks: with ZigBee, XBee, Arduino, and Processing.** O'Reilly Media, 2011. 322 p. ISBN 9780596807733. Disponível em:

FERREIRA, J. et al. Recommender system for drivers of electric vehicles. In: **ICECT 2011 - 2011 3rd International Conference on Electronics Computer Technology.** [S.l.: s.n.], 2011. v. 5, p. 244–248. ISBN 9781424486779.

FERRETTO, L. R.; CERVI, C. R.; MARCHI, A. C. B. de. Recommender systems in mobile apps for health a systematic review. In: **2017 12th Iberian Conference on Information Systems and Technologies (CISTI).** [S.l.: s.n.], 2017. p. 1–6.

FILHO, F. M. F.; GEUS, P. L.; ALBUQUERQUE, J. P. Sistemas de Recomendação e Interação na Web Social. **I Workshop de Aspectos da Interação Humano-Computador na Web Social**, p. 24–27, 2008. Disponível em: <http://www.academia.edu/download/30832515/websocial_ihc08>

FINEP. **Kevin Ashton – entrevista exclusiva com o criador do termo “Internet das Coisas”.** jan 2015. Disponível em: <<http://finep.gov.br/noticias/todas-noticias/4446-kevin-ashton-entrevista-exclusiva-com-o-criador-do-termo-internet-das-coisas>>.

FINKENZELLER, K. **RFID Handbook: Fundamentals and Applications in Contactless Smart Cards, Radio Frequency Identification and near-Field Communication**. Wiley, 2010.

ISSN 14337851. ISBN 9780470695067. Disponível em:

<<https://www.amazon.com/RFID-Handbook-Fundamentals-Identification-Communication-ebook/dp-/B005HF2GH8/%3FSubscriptionId/%3D0JYN1NVW651KCA56C102/%26tag/%3Dte20/%26linkCode/%3Dxm2/%26camp/%3D2025/%26creative/%3D1659>>.

FREEPIK. **Recursos gráficos gratuitos para designers**. 2017.

Disponível em: <<http://br.freepik.com>>. Acesso em: 30 de julho de 2017.

FRIKHA, M. et al. Using tmt ontology in trust based medical tourism recommender system. In: **2016 IEEE/ACS 13th International Conference of Computer Systems and Applications (AICCSA)**. [S.l.: s.n.], 2016. p. 1–8.

GARCIA, C. A.; FROZZA, R. Sistema de recomendação de produtos utilizando mineração de dados. **Tecno-lógica**, v. 1, n. 17, p. 78–90, 2013. Disponível em: <<https://online.unisc.br/seer/index.php-tecnologica/article/view/3283>>.

GAST, M. S. **802.11 Wireless Networks: The Definitive Guide, Second Edition**. O'Reilly Media, Inc., 2005. ISBN 0596100523.

Disponível em: <http://www.ebook.de/de/product/3296194-matthew_s_gast_802_11_wireless_networks_the_definitive_guide.html>.

GOLDBERG, D. et al. Using collaborative filtering to weave an information tapestry. **Communications of the ACM**, Association for Computing Machinery (ACM), New York, NY, USA, v. 35, n. 12, p. 61–70, dec 1992. ISSN 0001-0782.

GOMEZ, C.; PARADELLS, J. Wireless home automation networks: A survey of architectures and technologies. **IEEE Communications Magazine**, v. 48, n. 6, p. 92–101, June 2010. ISSN 0163-6804.

HACHANI, A. et al. RFID based smart fridge. In: **2016 8th IFIP International Conference on New Technologies, Mobility and Security (NTMS)**. Institute of Electrical and Electronics Engineers (IEEE), 2016. Disponível em:

<<https://doi.org/10.1109/2Fntms.2016.7792472>>.

HAMZA, M.; WALKER, R. J. Recommending features and feature relationships from requirements documents for software product lines. In: **2015 IEEE/ACM 4th International Workshop on Realizing Artificial Intelligence Synergies in Software Engineering**. [S.l.: s.n.], 2015. p. 25–31.

HUANG, A. S.; RUDOLPH, L. Bluetooth Essentials for Programmers. In: **Cambridge University Press**. Cambridge University Press, 2007. p. 210. ISBN 978-1-139-46546-5. Disponível em: <https://books.google.com.ar/books?id=s_djgV7\>.

HUSSAIN, M. I. Internet of things: challenges and research opportunities. **CSI Transactions on ICT**, Springer Nature, v. 5, n. 1, p. 87–95, dec 2016.

IEEE. **IEEE 802.15.4-2011**. IEEE, 2011. ISBN 0738166847. Disponível em: <<https://www.amazon.com/IEEE-802-15-4-2011/dp-/0738166847/%3FSubscriptionId%3D0JYN1NVW651KCA56C102/%26tag%3D20/%26linkCode%3Dxm2/%26camp%3D2025/%26creative%3D1659%3D>>.

IGOE, T.; COLEMAN, D.; JEPSON, B. **Beginning NFC: Near Field Communication with Arduino, Android, and PhoneGap**. first. O'Reilly Media, Inc., 2014. 246 p. ISBN 978-1-4493-7206-4. Disponível em: <<http://shop.oreilly.com/product/0636920021193.do>>.

JANNACH, D. et al. **Recommender Systems: An Introduction**. 1st. ed. New York, NY, USA: Cambridge University Press, 2010. ISBN 9780521493369.

JANNACH, D. et al. Recommender systems — beyond matrix completion. **Commun. ACM**, ACM, New York, NY, USA, v. 59, n. 11, p. 94–102, out. 2016. ISSN 0001-0782. Disponível em: <<http://doi.acm.org/10.1145/2891406>>.

JONES, W. P.; FURNAS, G. W. Pictures of relevance: A geometric analysis of similarity measures. **Journal of the American Society for Information Science**, Wiley-Blackwell, New York, NY, USA, v. 38, n. 6, p. 420–442, nov 1987. ISSN 0002-8231. Disponível em: <[http://dx.doi.org/10.1002/\(SICI\)1097-4571\(198711\)38:6<420::AID-ASI3>3.0.CO;2-S](http://dx.doi.org/10.1002/(SICI)1097-4571(198711)38:6<420::AID-ASI3>3.0.CO;2-S)>.

KARDACH, J. **Tech History: How Bluetooth got its name**. mar 2008. Disponível em: <http://www.eetimes.com/document.asp?doc_id=1269737page_number=1>.

KOREN, Y.; BELL, R.; VOLINSKY, C. Matrix factorization techniques for recommender systems. **Computer**, Institute of Electrical and Electronics Engineers (IEEE), Los Alamitos, CA, USA, v. 42, n. 8, p. 30–37, aug 2009. ISSN 0018-9162.

KORESHOFF, T. L.; ROBERTSON, T.; LEONG, T. W. Internet of things: a review of literature and products. In: **Proceedings of the 25th Australian Computer-Human Interaction Conference on Augmentation, Application, Innovation, Collaboration - OzCHI '13**. New York, New York, USA: ACM Press, 2013. p. 335–344. ISBN 9781450325257. Disponível em:

KRAWIEC, T. **The Amazon Recommendations Secret to Selling More Online**. 2016. Disponível em: <<http://rejoiner.com/resources/amazon-recommendations-secret-selling-online/>>.

KRULWICH, B. Lifestyle finder: Intelligent user profiling using large-scale demographic data. **AI magazine**, v. 18, n. 2, p. 37, 1997.

KUROSE, J. F.; ROSS, K. W. **Computer Networking: A Top-Down Approach**. [S.l.]: Pearson, 2012. ISBN 978-0132856201.

LABS, I. L. **Bluetooth Vs. Bluetooth Low Energy: What's The Difference?** nov 2015. Disponível em: <<https://www.link-labs.com/bluetooth-vs-bluetooth-low-energy/>>.

LEE, J. Smart factory systems. **Informatik-Spektrum**, Springer Nature, v. 38, n. 3, p. 230–235, may 2015.

LEINER, B. M. et al. **Brief History of the Internet**. 2012. Disponível em: <<http://www.internetsociety.org/internet/what-internet/history-internet/brief-history-internet>>.

LORENZI, F.; RICCI, F. Case-based recommender systems: A unifying view. In: _____. **Intelligent Techniques for Web Personalization: IJCAI 2003 Workshop, ITWP 2003, Acapulco, Mexico, August 11, 2003, Revised Selected Papers**. Berlin, Heidelberg: Springer Berlin Heidelberg, 2005. p. 89–113. ISBN 978-3-540-31655-8. Disponível em: <http://dx.doi.org/10.1007/11577935_5>.

LU, J. et al. Recommender system application developments: A survey. **Decision Support Systems**, v. 74, p. 12 – 32, 2015. ISSN 0167-9236. Disponível em: <<http://www.sciencedirect.com/science/article/pii/S0167923615000627>>.

Lü, L. et al. Recommender systems. **Physics Reports**, Elsevier BV, v. 519, n. 1, p. 1–49, oct 2012.

MASHAL, I.; CHUNG, T. Y.; ALSARYRAH, O. Toward service recommendation in internet of things. In: **2015 Seventh International Conference on Ubiquitous and Future Networks**. [S.l.: s.n.], 2015. p. 328–331. ISSN 2165-8528.

MATIAS-PEREIRA, J. **Manual de metodologia da pesquisa científica**. 3. ed.. ed. [S.l.]: Atlas, 2012. ISBN 9788522458615.

MEOLA, A. **What is the Internet of Things ?** dec 2016.
Disponível em: <<http://www.businessinsider.com/what-is-the-internet-of-things-definition-2016-8>>.

MEYERS, J. **Watch The Incredible 70-Year Evolution Of The Cell Phone**. 2011. Disponível em: <<http://www.businessinsider.com/complete-visual-history-of-cell-phones-2011-5?op=1/38-1>>.

MINIWATTS MARKETING GROUP. **World Internet Users Statistics and 2016 World Population Stats**. 2016. 3 p.
Disponível em: <<http://www.internetworldstats.com/stats.htm>>.

MIRANDA, A. C. d. P. Filtragem colaborativa incremental para recomendações automáticas na web. Faculdade de Economia da Universidade do Porto, 2010.

MITCHELL, T. M. **Machine Learning**. 1. ed. [S.l.]: McGraw-Hill Education, 1997. ISBN 9780070428072.

MONTUSCHI, P. et al. A semantic recommender system for adaptive learning. **IT Professional**, v. 17, n. 5, p. 50–58, Sept 2015. ISSN 1520-9202.

MUSTAFA, N. et al. Collaborative filtering: Techniques and applications. In: **2017 International Conference on Communication, Control, Computing and Electronics Engineering (ICCCCEE)**. [S.l.]: IEEE, 2017. p. 1–6.

NATH, K.; DHAR, S.; BASISHTHA, S. Web 1.0 to web 3.0 - evolution of the web and its various challenges. In: **2014 International Conference on Reliability Optimization and Information Technology (ICROIT)**. [S.l.]: IEEE, 2014. p. 86–89.

NFC FORUM. **About the Technology:** Nfc and contactless technologies. jan 2016. 1–2 p. Disponível em:
<http://nfc-forum.org/what-is-nfc/about-the-technology/>.

NFC FORUM. **Tag Type Technical Specifications.** jan 2016. Disponível em:
<http://nfc-forum.org/our-work/specifications-and-application-documents/specifications/tag-type-technical-specifications/>.

OLSSON, J. **6LoWPAN Overview.** 2014. Disponível em:
<http://www.ti.com/lit/wp/swry013/swry013.pdf>.

PANNIELLO, U.; GORGOGLIONE, M. Incorporating context into recommender systems: an empirical comparison of context-based approaches. **Electronic Commerce Research**, v. 12, n. 1, p. 1–30, Mar 2012. ISSN 1572-9362. Disponível em:
<https://doi.org/10.1007/s10660-012-9087-7>.

PAZZANI, M. J. A framework for collaborative, content-based and demographic filtering. **Artificial Intelligence Review**, v. 13, n. 5, p. 393–408, Dec 1999. ISSN 1573-7462. Disponível em:
<https://doi.org/10.1023/A:1006544522159>.

PERIYASAMY, M.; DHANASEKARAN, R. Evaluation of performance of uhf passive rfid system in metal and liquid environment. **2015 International Conference on Communication and Signal Processing, ICCSP 2015**, Institute of Electrical and Electronics Engineers (IEEE), p. 414–417, apr 2015.

QING, X.; CHEN, Z. N. Proximity effects of metallic environments on high frequency RFID reader antenna: Study and applications. **IEEE Transactions on Antennas and Propagation**, v. 55, n. 11 I, p. 3105–3111, 2007. ISSN 0018926X.

RESNICK, P. et al. GroupLens: An open architecture for collaborative filtering of netnews. In: **Proceedings of the 1994 ACM conference on Computer supported cooperative work - CSCW '94**. New York, NY, USA: ACM Press, 1994. (CSCW '94), p. 175–186. ISBN 0-89791-689-1. Disponível em:
<http://doi.acm.org/10.1145/192844.192905>.

RICCI, F. et al. **Recommender Systems Handbook**. 1st. ed. New York, NY, USA: Springer-Verlag New York, Inc., 2010. ISBN 0387858199, 9780387858197.

RUSSELL, S.; NORVIG, P. **Artificial Intelligence: A Modern Approach**. [S.l.]: PRENTICE HALL, 2009. ISBN 978-0-13-604259-4.

SALMAN, Y. et al. A proactive multi-type context-aware recommender system in the environment of internet of things. In: **2015 IEEE International Conference on Computer and Information Technology; Ubiquitous Computing and Communications; Dependable, Autonomic and Secure Computing; Pervasive Intelligence and Computing**. [S.l.: s.n.], 2015. p. 351–355.

SCHREIBER, G. et al. **Knowledge Engineering and Management**. [S.l.]: MIT Press Ltd, 1999. ISBN 9780262193009.

SHARMA, R.; GOPALANI, D.; MEENA, Y. Collaborative filtering-based recommender system: Approaches and research challenges. In: **2017 3rd International Conference on Computational Intelligence Communication Technology (CICT)**. [S.l.: s.n.], 2017. p. 1–6.

SHWETA, A. Intelligent refrigerator using ARTIFICIAL INTELLIGENCE. In: **2017 11th International Conference on Intelligent Systems and Control (ISCO)**. IEEE, 2017. p. 464–468. ISBN 978-1-5090-2717-0. Disponível em: <<http://ieeexplore.ieee.org/document/7856036/>>.

SILVA, L. C. D. et al. State of the art of smart homes. **Engineering Applications of Artificial Intelligence**, Elsevier, v. 25, n. 7, p. 1313–1321, oct 2012. ISSN 0952-1976. Disponível em: <<http://www.sciencedirect.com/science/article/pii/S095219761200098X>>.

SMIRNOV, A. et al. Recommendation system for tourist attraction information service. In: **14th Conference of Open Innovation Association FRUCT**. [S.l.: s.n.], 2013. p. 148–155. ISSN 2305-7254.

SMITH, B.; LINDEN, G. Two decades of recommender systems at amazon.com. **IEEE Internet Computing**, v. 21, n. 3, p. 12–18, May 2017. ISSN 1089-7801.

STÄNDER, M. et al. A smart kitchen infrastructure. **Proceedings - 2012 IEEE International Symposium on Multimedia, ISM 2012**, Institute of Electrical and Electronics Engineers (IEEE), p. 96–99, dec 2012.

STOJKOSKA, R. et al. A review of Internet of Things for smart home: Challenges and solutions. **Journal of Cleaner Production**, Elsevier Ltd, v. 140, p. 1454–1464, jan 2017. ISSN 09596526. Disponível em: <<http://www.sciencedirect.com/science/article/pii/S095965261631589X>>.

SURESH, P. et al. A state of the art review on the Internet of Things (IoT) history, technology and fields of deployment. In: **2014 International Conference on Science Engineering and Management Research (ICSEMR)**. Institute of Electrical and Electronics Engineers (IEEE), 2014. p. 1–8. ISBN 978-1-4799-7613-3. ISSN 10952055. Disponível em: <<http://ieeexplore.ieee.org/lpdocs/epic03/wrapper.htm?arnumber=7043637>>. Acesso em: 9 apr. 2017.

SYED, M. H.; FERNANDEZ, E. B.; ILYAS, M. A Pattern for Fog Computing. In: **Proceedings of the 10th Travelling Conference on Pattern Languages of Programs**. New York, NY, USA: ACM, 2016. (VikingPLoP '16), p. 1–10. ISBN 9781450342001. Disponível em: <<http://doi.acm.org/10.1145/3022636.3022649>>.

THOMAS, A.; SUJATHA, A. K. Comparative study of recommender systems. In: **2016 International Conference on Circuit, Power and Computing Technologies (ICCPCT)**. [s.n.], 2016. p. 1–6. ISBN 978-1-5090-1277-0. Disponível em: <<http://ieeexplore.ieee.org/lpdocs/epic03/wrapper.htm?arnumber=7530304>>.

VAQUERO, L. M.; RODERO-MERINO, L. Finding your way in the fog. **ACM SIGCOMM Computer Communication Review**, Association for Computing Machinery (ACM), v. 44, n. 5, p. 27–32, oct 2014. Disponível em: <<https://doi.org/10.1145/2677046.2677052>>.

WAI, L. Data science at udemy: Agile experimentation with algorithms. In: **2016 Future Technologies Conference (FTC)**. [S.l.: s.n.], 2016. p. 355–360.

WILSON, C.; HARGREAVES, T.; HAUXWELL-BALDWIN, R. Smart homes and their users: a systematic analysis and key challenges. **Personal and Ubiquitous Computing**, Springer Nature, v. 19, n. 2, p. 463–476, sep 2015. ISSN 16174909.

WOYKE, E. **The Smartphone: Anatomy of an Industry**. [S.l.]: The New Press, 2014. ISBN 9781595589682.

YEUNG, K. F.; YANG, Y. A proactive personalized mobile news recommendation system. In: **Proceedings - 3rd International Conference on Developments in eSystems Engineering, DeSE 2010**. [S.l.: s.n.], 2010. p. 207–212. ISBN 9780769541600.

Z-WAVE ALLIANCE. **About Z-Wave Technology**. 2015.

Disponível em:

<http://z-wavealliance.org/about_z-wave_technology/>.

ZANELLA, A. et al. Internet of things for smart cities. **IEEE Internet of Things Journal**, v. 1, n. 1, p. 22–32, Feb 2014. ISSN 2327-4662.